

SVEUČILIŠTE U ZAGREBU
FAKULTET ELEKTROTEHNIKE I RAČUNARSTVA

DIPLOMSKI RAD br. 1467

**MODELI DIFUZIJE U LATENTNOM PROSTORU ZA
GENERIRANJE GLAZBE IZ AUDIO SIGNALA**

Matej Magat

Zagreb, lipanj 2026.

SVEUČILIŠTE U ZAGREBU
FAKULTET ELEKTROTEHNIKE I RAČUNARSTVA

DIPLOMSKI RAD br. 1467

**MODELI DIFUZIJE U LATENTNOM PROSTORU ZA
GENERIRANJE GLAZBE IZ AUDIO SIGNALA**

Matej Magat

Zagreb, lipanj 2026.

DIPLOMSKI ZADATAK br. 1467

Pristupnik: **Matej Magat (0036541718)**

Studij: Računarstvo

Profil: Računarska znanost

Mentor: prof. dr. sc. Goran Delač

Zadatak: **Modeli difuzije u latentnom prostoru za generiranje glazbe iz audio signala**

Opis zadatka:

Istražiti i opisati modele difuzije za generiranje glazbe, s posebnim naglaskom na arhitekture koje kombiniraju autoenkoder za učenje latentne reprezentacije audio signala i difuzijski model za generiranje novih uzoraka u latentnom prostoru. Analizirati metode reprezentacije audio signala te osmisliti i programski ostvariti autoenkoderski model koji preslikava audio signal u latentni prostor smanjene dimenzionalnosti. Osmisliti i programski ostvariti difuzijski model u naučenom latentnom prostoru koji ima sposobnost generiranja novih audio uzoraka. Koristiti javno dostupni skup podataka za treniranje i vrednovanje modela (primjerice, MUSDB18). Osmisliti i provesti postupak vrednovanja kvalitete generiranih audio uzoraka primjenom objektivnih metrika (npr. rekonstrukcijska pogreška, spektralne metrike, perceptualne metrike) te provesti subjektivnu analizu nad odgovarajućim uzorkom.

Rok za predaju rada: 26. lipnja 2026.

*Želio bih izraziti zahvalnost svom mentoru, Goranu Delaču, na njegovoj strpljivosti,
smirenosti, pozitivnosti i savjetima tijekom studiranja.*

Sažetak

Modeli difuzije u latentnom prostoru za generiranje glazbe iz audio signala

Matej Magat

Generiranje glazbe zahtjevan je zadatak za duboke neuronske mreže zbog složene strukture zvuka koja uključuje brze tranzijente, harmonijske progresije i melodijske obrasce oblikovane glazbenom tradicijom. Dodatni izazov predstavlja visoka vremenska rezolucija digitalnog zvuka; jedna sekunda pri 44,1 kHz sadrži 44 100 uzoraka, pa se glazbeni odnosi protežu kroz velik broj vremenskih koraka.

Ovaj rad predstavlja sustav koji ublažava te izazove korištenjem log-mel spektrograma, kompresije u latentni prostor varijacijskim autoenkoderom (VAE) te difuzijskog modela temeljenog na U-Net arhitekturi u tom prostoru. Sustav je treniran i evaluiran na skupu MUSDB18 (150 profesionalnih skladbi, 44,1 kHz), koristeći mješavine za generiranje glazbe bez uvjetovanja dodatnim podacima.

Evaluacija uključuje Fréchet Audio Distance (FAD) za procjenu distribucijske sličnosti između generiranog i stvarnog zvuka te spektralne deskriptore koji opisuju boju zvuka.

Ključne riječi: Generiranje glazbe; Latentni difuzijski modeli; U-Net denoiser; Varijacijski autoenkoder; Latentni prikaz zvuka; MUSDB18

Abstract

Latent Space Diffusion Models for Music Generation from Audio Signals

Matej Magat

Music generation is a challenging task for deep neural networks due to the complex structure of audio signals, including sub-millisecond transients, harmonic progressions, and melodies shaped by long-standing musical conventions. The high temporal resolution of digital audio adds further difficulty; one second at 44.1 kHz contains 44,100 samples, requiring models to capture dependencies across many time steps.

This thesis presents a system that addresses these challenges using log-mel spectrograms, compression into a latent space with a variational autoencoder (VAE), and a diffusion model based on a U-Net architecture operating in that space. The system is trained and evaluated on the MUSDB18 dataset (150 professionally recorded tracks at 44.1 kHz), using mixtures to generate new music without conditioning on text, labels, or metadata.

Evaluation uses the Fréchet Audio Distance (FAD) to measure distributional similarity between generated and real audio via deep embeddings, along with spectral descriptors capturing timbral characteristics.

Keywords: Music generation; Latent diffusion models; U-Net denoiser; Variational Autoencoder; Latent audio representations; MUSDB18

Sadržaj

Sažetak	1
Abstract	2
1. Uvod	7
1.1. Motivacija	7
1.2. Opis problema i istraživački ciljevi	8
1.3. Struktura rada	9
2. Opis područja problema	10
2.1. Reprezentacije audio signala	10
2.1.1. Valni oblik	10
2.1.2. Kratkotrajna Fourierova transformacija	10
2.1.3. Mel spektrogram	11
2.1.4. Log-mel spektrogram	12
2.1.5. Mel-frekventni kepsralni koeficijenti	12
2.1.6. Neuronski audio kodeci	12
2.1.7. Opravdanje odabira mel spektrograma	13
2.2. Generativni modeli za zvuk i glazbu	13
2.2.1. Autoregresivni modeli	14
2.2.2. Generativne suparničke mreže	14
2.2.3. Varijacijski autoenkoderi	15
2.2.4. Normalizirajući tokovi	15
2.2.5. Difuzijski modeli	16
2.2.6. Sinteza	16
2.3. Difuzijski modeli: osnove i varijante	17

2.3.1.	Unaprijedni proces difuzije	17
2.3.2.	Obrnuti proces difuzije	17
2.3.3.	Implicitni modeli difuzije s uklanjanjem šuma (DDIM)	18
2.3.4.	Rasporedi šuma	18
2.3.5.	Latentni difuzijski modeli	18
2.3.6.	Uvjetovanje bez klasifikatora	19
2.4.	Autoenkoderi za učenje latentnog prostora zvuka	19
2.4.1.	Standardni autoenkoderi	19
2.4.2.	Varijacijski autoenkoder	20
2.4.3.	β -VAE	20
2.4.4.	Kolaps posteriora	21
2.4.5.	Konvolucijski VAE za spektrograme	21
2.4.6.	Neuronski audio kodeci	21
2.4.7.	Praktični aspekti VAE-a za mel spektrograme	22
2.5.	Latentni difuzijski modeli za generiranje glazbe	22
2.5.1.	AudioLDM	22
2.5.2.	MusicLDM	23
2.5.3.	Multi-Track MusicLDM	23
2.5.4.	Stable Audio	23
2.5.5.	Moûsai	24
2.5.6.	Difuzijsko-transformerska arhitektura	24
2.5.7.	Pozicioniranje ovog rada	24
2.6.	Skupovi podataka za generiranje glazbe	25
2.6.1.	MUSDB18	25
2.6.2.	MusicCaps	26
2.6.3.	Free Music Archive	26
2.7.	Evaluacija generativnih audio modela	26
2.7.1.	Fr�chetova audio udaljenost	27
2.7.2.	Kernelska audio udaljenost	27
2.7.3.	Srednja ocjena mi�ljenja	27
2.7.4.	MUSHRA	28
2.7.5.	Spektralne metrike	28

2.7.6.	Metrike na razini signala	28
2.7.7.	Pregled evaluacijskih metrika	29
3.	Opis problema i programsko ostvarenje	30
3.1.	Opis problema	30
3.1.1.	Definicija zadatka i ograničenja	30
3.1.2.	Skup podataka MUSDB18	31
3.2.	Predloženo rješenje: pregled sustava	32
3.3.	Korištene tehnologije i knjižnice	33
3.4.	Računalni resursi	33
3.5.	Obrada podataka	33
3.5.1.	Izvoz mješavina iz MUSDB18	34
3.5.2.	Rezanje na isječke	34
3.5.3.	Mel-spektrogramska reprezentacija i normalizacija	34
3.6.	Varijacijski autoenkoder	36
3.6.1.	Arhitektura enkodera i dekodera	36
3.6.2.	Latentna reprezentacija i reparametrizacijski trik	37
3.6.3.	Funkcija gubitka i žarenje KL termina	38
3.6.4.	Postupak učenja	39
3.7.	Difuzijski model u latentnom prostoru	39
3.7.1.	Raspored šuma i unaprijedni proces	40
3.7.2.	Arhitektura U-Net denoisera	41
3.7.3.	Vremenska ugradnja	42
3.7.4.	Funkcija gubitka i postupak učenja	43
3.8.	Inferencija i generiranje zvuka	44
3.8.1.	DDPM obrnuti proces uzorkovanja	45
3.8.2.	Inverzna pretvorba spektrograma u zvuk (Griffin-Lim)	46
4.	Opis postupka vrednovanja i rezultati	48
4.1.	Krivulje učenja varijacijskog autoenkodera	48
4.2.	Kvaliteta rekonstrukcije varijacijskog autoenkodera	49
4.3.	Analiza latentnog prostora varijacijskog autoenkodera	52
4.4.	Konvergencija učenja difuzijskog modela	54

4.5. Spektralni deskriptori generiranih uzoraka	55
4.6. Kvaliteta generiranih uzoraka	57
4.7. Subjektivna analiza generiranih uzoraka	57
5. Zaključak	60
Literatura	62
Izjava o korištenju umjetne inteligencije	68

1. Uvod

1.1. Motivacija

Generativno modeliranje doživjelo je izrazit napredak tijekom ovog desetljeća u računalnom vidu, obradi prirodnoga jezika te, naposljetku, u glazbi i videu. Suvremeni sustavi generiranja slika temeljeni na difuziji stvaraju realistične slike visoke rezolucije, što označava znatan pomak u odnosu na prijašnje mutne i nerazpoznatljive rezultate. U obradi prirodnoga jezika autoregresivni transformeri danas proizvode opsežne, koherentne tekstove i obavljaju zadatke koji su nekoć zahtijevali znatnu domensku stručnost. Generiranje glazbe i videa kasnije je ušlo u razdoblje brzog napretka jer se temelji na otkrićima iz područja generiranja slika i obrade prirodnoga jezika.

Generiranje glazbe složen je zadatak za generativno modeliranje dubokim neuronskim mrežama zbog visoke dimenzionalnosti, složene i međusobno povezane strukture te istodobno aktivnih vremenskih skala. Pojedinačni tranzijenti različitih instrumenata često su kraći od milisekunde, dok ritmički uzorci ili harmonijski odnosi traju više sekundi. Na višoj razini postoji i struktura skladbe sastavljena od ponavljajućih ideja, fraza, refrena ili kitica koje se protežu kroz više minuta. Dugodosežna koherencija na tim razinama nužna je kako bi se glazba doživjela kao namjerna i strukturirana, a ne nasumična. Taj izazov modeliranja ovisnosti kroz cijelu tu hijerarhiju istodobno znatno je veći od izazova u generiranju slika, gdje su prostorne ovisnosti lokalne i ne uključuju vremensko uređenje.

Glazba postavlja stroge zahtjeve na koherenciju glavnog vokala i harmonijske strukture. Akordi moraju biti interno konzistentni, a melodijske linije razrješavati se na način koji zadovoljava harmonijska očekivanja. Međuodnos istodobno zvučećih glasova, uključujući njihov relativni intenzitet, stapanje boje zvuka i vremensko usklađenje, mora

biti u skladu s pravilima glazbene teorije. Ta ograničenja nisu binarna pravila, već probabilistička očekivanja oblikovana kulturnom prepoznatljivošću, a odstupanja su zamjetna čak i slušateljima bez formalne glazbene naobrazbe.

Slušatelji su izvanredno osjetljivi na artefakte u zvuku i glazbi. Ljudski slušni sustav evoluirao je kako bi detektirao suptilna odstupanja u periodičkim signalima te je osobito osjetljiv na vrste spektralnog razmazivanja, fazne nekoherencije i vremenskog zamućivanja koje se uobičajeno javljaju kao greške dubokih modela generacije zvuka ili algoritama poput Griffin-Lim. Ta perceptivna osjetljivost znači da čak i kvantitativno male razlike u kvaliteti signala mogu rezultirati značajnom percipiranom degradacijom.

Postoji značajna i praktična motivacija za suočavanje s tim izazovima. Automatsko generiranje glazbe ima izravne primjene u kreativnim alatima za profesionalne skladatelje i producente, u sustavima automatske glazbene pratnje koji u stvarnom vremenu reagiraju na izvođače, u proceduralno generiranom zvuku za videoigre koji se dinamički prilagođava ponašanju igrača, u filmskom i medijskom ozvučivanju te u alatima za pristupačnost koji korisnicima bez glazbenog obrazovanja omogućuju stvaranje personaliziranog zvučnog materijala. Kako se te primjene budu razvijale, potražnja za sustavima sposobnima proizvoditi visokovjerni, glazbeno koherentan audio samo će rasti.

Posljednji, ali temeljni izazov odnosi se na računalnu reprezentaciju zvukovnog signala. Jedna sekunda zvuka uzorkovana frekvencijom od 44,1 kHz sadrži 44 100 uzoraka. Treniranje generativnih modela izravno na valnom obliku stoga je računalno zahtjevno: autoregresivni modeli moraju obrađivati uzorke sekvencijalno, a konvolucijske i arhitekture temeljene na pažnji moraju održavati ovisnosti kroz nepraktično duge slijedove. Zbog toga se koriste kompaktniji zapisi, poput log-mel spektrograma, naučenih latentnih reprezentacija ili diskretnih tokena, koje zadržavaju perceptivno važan sadržaj izvornog signala, a pritom značajno smanjuju dimenzionalnost prostora u kojem generativni model djeluje.

1.2. Opis problema i istraživački ciljevi

Ovaj se rad bavi problemom bezuvjetnog generiranja glazbe: sintezom novog glazbenog zapisa koji je perceptivno uvjerljiv i glazbeno koherentan, a koji proizvodi model uvjež-

ban na skupu stvarne glazbe bez ikakvog uvjetovanja tekstom, oznakama ili metapodacima u trenutku inferencije. Sustav je uvježban isključivo na skupu podataka MUSDB18, zbirci od 150 profesionalno snimljenih višekanalnih glazbenih djela koja obuhvaćaju raznolike žanrove, a koja se ovdje koristi u potpuno miksanom obliku.

Središnja pretpostavka koja vodi implementacijske odluke u ovom radu jest da provođenje generativnog difuzijskog procesa u kompaktnom latentnom prostoru zamrznutog varijacijskog autoenkodera, umjesto izravno u prostoru izvornog valnog oblika ili puno-rezolucijskog spektrograma, značajno smanjuje dimenzionalnost problema generiranja i čini ga rješivim s računalnim resursima dostupnima u akademskom okruženju.

Kako bi se ta pretpostavka ispitala, rad slijedi dva glavna istraživačka cilja. Prvo, procjenjuje se može li varijacijski autoenkoder naučiti kompaktan, gladak i dobro strukturiran latentni prikaz mel spektrograma glazbe koji je pogodan kao generativni cilj za latentni difuzijski model. To uključuje procjenu vjernosti rekonstrukcije, usklađenosti agregiranog posteriora s izotropnom Gaussovom priornom raspodjelom te svojstava kontinuiteta latentnog prostora koja podupiru stabilno naknadno učenje.

Drugo, ispituje se može li latentni difuzijski model, uvježban na VAE-kodiranim glazbenim reprezentacijama, točno modelirati distribuciju latentnih reprezentacija i generirati uzorke koji, nakon dekodiranja, rezultiraju perceptivno uvjerljivim i glazbeno koherentnim zvukom. Ovaj se cilj usredotočuje na krajnju generativnu sposobnost predloženog sustava i njegovu sposobnost obuhvaćanja strukture glazbe u sažetoj reprezentaciji.

1.3. Struktura rada

Preostali dio rada organiziran je kako slijedi. Drugo poglavlje donosi pregled područja problema i srodnih radova, uključujući reprezentacije zvučnog signala, obitelji generativnih modela za zvuk i glazbu, matematičke osnove difuzijskih modela, autoenkoderske arhitekture za učenje latentnog prostora, latentne difuzijske sustave za generiranje glazbe, skupove podataka te metode evaluacije. Treće poglavlje predstavlja predloženu arhitekturu sustava, uključujući skup podataka i pretprocesiranje, postupke učenja te cjelokupnu inferencijsku proceduru. Četvrto poglavlje donosi eksperimentalnu evaluaciju. Peto poglavlje zaključuje rad.

2. Opis područja problema

2.1. Reprezentacije audio signala

Odabir reprezentacije audiosignala prvi je korak u svakom pristupu generativnom modeliranju jer određuje dimenzionalnost prostora u kojem model djeluje i stupanj u kojem je perceptivno relevantna struktura eksplicitno izražena u samoj reprezentaciji. Ovaj odjeljak daje pregled glavnih reprezentacija i njihove prikladnosti za generativno modeliranje.

2.1.1. Valni oblik

Najizravniji prikaz audiosignala jest digitalizirani slijed vrijednosti amplitude u vremenskoj domeni. Zvučni signal tipično se uzorkuje frekvencijom od 44,1 kHz za konzumerske ili 48 kHz za profesionalne primjene. Kao što je već spomenuto, valni oblik predstavlja iznimno zahtjevan cilj generativnog modeliranja jer se sastoji od vrlo velikog broja uzoraka s brojnim međuovisnostima na različitim vremenskim skalama. Izravno generativno modeliranje na toj razini razlučivosti postignuto je, ponajprije u radovima WaveNet [1] i Jukebox [2], ali uz cijenu velikog računalnog troška i, u autoregresivnom slučaju, sekvencijalnog generiranja uzorka po uzorak, što inferenciju čini nepraktično sporom za većinu primjena.

2.1.2. Kratkotrajna Fourierova transformacija

Kratkotrajna Fourierova transformacija (STFT) pruža vremensko–frekvencijsku dekompoziciju valnog oblika primjenom diskretne Fourierove transformacije (DFT) na uzastopne preklapajuće prozore signala. Za prozor duljine L uzoraka s pomakom H , STFT

daje kompleksno vrijednu matricu

$$X \in \mathbb{C}^{(L/2+1) \times T},$$

gdje je

$$T = \left\lfloor \frac{N-L}{H} \right\rfloor + 1$$

broj okvira, a N ukupna duljina signala.

Spektrogram snage,

$$|X|^2,$$

odbacuje faznu informaciju i predstavlja raspodjelu energije kroz vrijeme i frekvenciju.

Temeljno ograničenje STFT-a jest fiksni kompromis između vremenske i frekvencijske razlučivosti, nametnut Heisenbergovim načelom neodređenosti [3]: dulji prozor daje bolju frekvencijsku razlučivost, ali lošiju vremensku, i obratno. Taj kompromis znači da nijedna parametarizacija STFT-a ne može istodobno dobro razriješiti i fine vremenske događaje (tranzijente) i gusto zbijene frekvencijske komponente (harmonike), što predstavlja stvaran izazov za glazbene signale koji sadrže oboje.

2.1.3. Mel spektrogram

Mel spektrogram ublažava ograničenja rezolucije linearnog spektrograma snage projekcijom na mel-perceptualnu skalu, koja aproksimira nelinearnu frekvencijsku razlučivost ljudskog slušnog sustava. Mel skala je približno linearna ispod oko 1 kHz, a približno logaritamska iznad, odražavajući činjenicu da slušni sustav ima otprilike konstantnu relativnu (a ne apsolutnu) frekvencijsku razlučivost u širokom srednjem području. Skup M mel-razmaknutih filtara primjenjuje se na spektrogram snage kako bi se dobio mel spektrogram $S \in \mathbb{R}_{\geq 0}^{M \times T}$, gdje je M tipično u rasponu 64–128, a T je broj vremenskih okvira. Mel spektrogram postiže značajnu redukciju dimenzionalnosti u usporedbi sa sirovim valnim oblikom, uz zadržavanje akustički i glazbeno relevantnih obilježja: visina tona uglavnom je enkodirana u položaju spektralnih vrhova, boja zvuka u obliku spektralne ovojnice, ritmička struktura u vremenskoj modulaciji energije, a dinamički raspon u ukupnoj razini energije. Ta svojstva čine mel spektrogram prirodnom i široko

korištenom međureprezentacijom za obradu zvuka temeljenu na učenju.

2.1.4. Log-mel spektrogram

U praksi se gotovo uvijek preferira logaritam mel spektrograma: $S_{\log} = \log(S + \epsilon)$, gdje je ϵ mala vrijednost koja sprječava numeričke probleme za binove s gotovo nultom energijom. Log-transformacija sažima vrlo širok dinamički raspon reprezentacije i preslikava ga u uži interval prikladniji za učenje neuronskih mreža. Osim toga, približava reprezentaciju decibelskoj skali perceptualne glasnoće te često rezultira „urednijom” distribucijom vrijednosti obilježja, koja se u praksi pokazala pogodnijom za mnoge modele dubokog učenja [4].

2.1.5. Mel-frekventni kepralni koeficijenti

Mel-frekventni kepralni koeficijenti (engl. *Mel-Frequency Cepstral Coefficients*, MFCC) izvode se iz log-mel spektrograma primjenom diskretne kosinusove transformacije (DCT), čime se dobiva kompaktan skup koeficijenata (tipično 13–40) koji enkodira grubu spektralnu ovojniciu. MFCC-i su desetljećima bili dominantna reprezentacija u prepoznavanju govora te su opsežno korišteni i u pretraživanju glazbenih informacija. Međutim, kao ciljna reprezentacija za generativno modeliranje odbacuju finu spektralnu strukturu nužnu za rekonstrukciju zvuka visoke vjernosti, što ih čini manje prikladnima od punog log-mel spektrograma za zadatke sinteze kojima se ovaj rad bavi.

2.1.6. Neuronski audio kodeci

Novija obitelj reprezentacija, primjerice EnCodec [5] i DAC (Descript Audio Codec) [6], koristi naučene neuronske mreže za generiranje kompaktnih nizova diskretnih tokena putem rezidualne kvantizacije vektora (engl. *Residual Vector Quantisation*, RVQ). Ti kodeci uvježbavaju se s učenjem od početka do kraja (engl. *end-to-end training*) s ciljem perceptualne rekonstrukcije, pri čemu se koristi GAN diskriminator, a postižu izrazito kompaktne reprezentacije uz podršku rekonstrukciji visoke vjernosti uz gubitke. Tokeni neuronskih kodeka usvojeni su kao ciljna reprezentacija za autoregresivno generiranje u stilu jezičnih modela (npr. AudioLM, MusicGen) i predstavljaju značajan odmak od ručno konstruiranih spektralnih obilježja. Međutim, diskretna priroda reprezentacije

tokena manje je prirodna kao cilj za difuzijske modele kontinuiranih vrijednosti, koji su dizajnirani za uklanjanje šuma iz kontinuiranog Gaussovog šuma.

2.1.7. Opravdanje odabira mel spektrograma

S obzirom na navedene karakteristike pojedinih reprezentacija, log-mel spektrogram odabran je kao primarna međureprezentacija u ovome radu iz sljedećih razloga:

- postiže značajnu redukciju dimenzionalnosti u odnosu na valni oblik uz zadržavanje perceptualno relevantne glazbene strukture,
- radi se o dobro razumljivoj, determinističkoj transformaciji s utvrđenim alatima za predprocesiranje,
- kao reprezentacija kontinuiranih vrijednosti izravno je pogodna za VAE enkodiranje i latentnu difuziju,
- mel spektrogrami pokazali su se učinkovitim ulazima i izlazima za duboke generativne modele [4],
- rekonstrukcija iz mel spektrograma u valni oblik dobro je istražen problem koji rješavaju i klasična procjena faze (Griffin–Lim [7]) i neuronski vokoderi (HiFi-GAN [8]), što omogućuje kontroliranu ablacijsku studiju tog odabira rekonstrukcijskog koraka.

2.2. Generativni modeli za zvuk i glazbu

Problem generiranja zvuka visoke kvalitete rješavan je nizom paradigmi modeliranja, svaka s karakterističnim prednostima i nedostacima. Ovaj odjeljak pregledava glavne obitelji otprilike kronološkim redoslijedom te uspostavlja kontekst u kojemu se difuzijski pristup ovoga rada smješta u odnosu na šire istraživačko područje.

2.2.1. Autoregresivni modeli

Autoregresivni modeli raspisuju zajedničku distribuciju audio signala kao produkt uvjetnih distribucija:

$$p(\mathbf{x}) = \prod_{t=1}^T p(x_t | x_{<t}),$$

te uvježbavaju neuronsku mrežu za predviđanje svakog uzorka na temelju svih prethodnih. WaveNet [1] uveo je razrijeđene uzročne konvolucije kao mehanizam za učinkovito proširenje receptivnog polja bez proporcijalnog povećanja računalnog troška, čime je omogućeno zahvaćanje dugodominnih ovisnosti u sirovim audio valnim oblicima. WaveNet je postigao vrhunsku izvedbu u sintezi govora i pokazao da neuronski autoregresivni modeli mogu generirati uvjerljiv zvuk na razini valnog oblika. SampleRNN [9] proširio je ovaj pristup hijerarhijskom višeskalnom arhitekturom koja istodobno operira na različitim vremenskim rezolucijama, pri čemu svaki viši modul uvjetuje onaj niži. Jukebox [2] primjenjuje hijerarhijski VQ-VAE za kompresiju sirovog zvuka u višeskalne nizove diskretnih tokena, a zatim uvježbava zasebne autoregresivne transformerske modele na rezultirajućim nizovima, što omogućuje generiranje glazbe s prepoznatljivom strukturom u vremenskim skalama od nekoliko minuta. Glavne prednosti autoregresivnih modela su točno računanje log-izglednosti i prirodan kapacitet za modeliranje dugodominnih ovisnosti (long-range dependency) putem sekvencijalnog uvjetovanja. Njihova ključna slabost jest brzina inferencije: autoregresivno generiranje zvuka na razini uzorka inherentno je sekvencijalno i ne može se paralelizirati, što sintezu u stvarnom vremenu čini nepraktičnom za većinu scenarija primjene. Nadalje, znatan dio autoregresivnog kapaciteta troši se na modeliranje detalja valnog oblika niske razine na štetu glazbene strukture visoke razine.

2.2.2. Generativne suparničke mreže

Generativne suparničke mreže (engl. *Generative Adversarial Networks*, GAN) uvježbavaju generator i diskriminator u suparničkoj igri, tjerajući generator da proizvodi izlaze koji su nerazlučivi od stvarnih podataka prema kriteriju diskriminatora. Za zvuk, GAN-ovi su pronašli posebno uspješnu primjenu kao sustavi koji rekonstruiraju valni oblik iz mel spektrograma (neuronski vokoder). HiFi-GAN [8] uveo je višeperiodni diskriminator i višeskalni diskriminator koji operira na različitim razinama podnabiranja, u

kombinaciji s višerezolucijskim STFT gubitkom, čime je postigao kvalitetu zvuka koja je značajno nadmašila klasične metode i ranije GAN vokoderske pristupe uz održavanje brze inferencije. MelGAN [10] je demonstrirao brzo GAN-bazirano generiranje valnog oblika iz mel spektrograma, dok je WaveGAN [11] istraživao nenadziranu sintezu zvuka izravno iz šuma. Glavne prednosti GAN-ova za zvuk su brza paralelna inferencija i visoka perceptualna kvaliteta. Njihove slabosti uključuju nestabilnost suparničkog uvježbavanja, osjetljivost na kolaps modova te odsutnost eksplicitne log-izglednosti, što otežava evaluaciju i usporedbu modela.

2.2.3. Varijacijski autoenkoderi

VAE-i [12] pružaju probabilistički generativni okvir u kojemu enkoderska mreža preslikava opažanja na distribuciju nad latentnim kodovima, a dekoderska mreža preslikava latentne kodove natrag na opažanja. Ciljna funkcija donje granice dokaza (engl. *Evidence Lower Bound*, ELBO) uvježbava model za vjerno rekonstruiranje ulaza uz poticanje aproksimativnog posteriora da ostane blizak jednostavnom prioru (tipično izotropnom Gaussovom). Za generiranje zvuka, VAE-i nude gladak, kontinuiran latentni prostor pogodan kao međureprezentacija za naknadne generativne modele. Glavne slabosti VAE-a kao samostalnog generativnog sustava su tendencija generiranja mutnih ili preglađenih izlaza, uzrokovana rekonstrukcijskim gubitkom koji usrednjuje višestruke načine raspodjele podataka te kolaps posteriora: kvar u kojemu enkoder prestaje enkodirati smislene informacije jer snažan dekodek nauči rekonstruirati ulaz ignorirajući latentni kod, a KL divergencija po dimenzijama pada na nulu [13]. Mjere ublažavanja, kao što su postupno povećavanje težine KL člana (KL annealing) i arhitektonski odabiri koji ograničavaju kapacitet dekodera, predložene su u literaturi, ali perceptualna oštrina zvuka generiranog VAE-em generalno zaostaje za GAN-ovima i difuzijskim modelima kada se VAE koristi kao samostalni generativni sustav.

2.2.4. Normalizirajući tokovi

Modeli normalizirajućih tokova uče invertibilnu transformaciju između jednostavne bazne distribucije (tipično Gaussove) i distribucije podataka, što omogućuje točno računanje log-izglednosti i učinkovito uzorkovanje. WaveGlow [14] je prilagodio Glow arhitekturu sirovim audio valnim oblicima, postići konkurentnu kvalitetu sinteze govora. Glavno

ograničenje normalizirajućih tokova jest arhitektonsko: zahtjev da transformacija bude invertibilna i da ima izračunljivu determinantu Jakobijana nameće snažna ograničenja na dizajn modela, tipično nalažući slojeve spajanja ili druge strukturirane arhitekture koje ograničavaju ekspresivnost po parametru. Trošak memorije također je visok, budući da se pri učenju moraju zadržati svi međuizrazi potrebni za izračun Jakobijana i propagaciju gradijenata.

2.2.5. Difuzijski modeli

Difuzijski probabilistički modeli s uklanjanjem šuma (engl. *Denosing Diffusion Probabilistic Models*, DDPM) [15] i njihovi analozi u kontinuiranom vremenu (modeli temeljeni na rezultatu [16]) pojavili su se kao dominantna paradigma za generativno modeliranje visoke kvalitete u različitim modalitetima. DiffWave i WaveGrad [17] demonstrirali su da difuzijski modeli mogu generirati govorni zvuk visoke kvalitete izravno u domeni valnog oblika. Difuzijski modeli uvježbavaju neuronsku mrežu za obrtanje fiksnog Markovljevog lanca koji postupno dodaje podacima Gaussov šum, a uzorkovaju iterativnim uklanjanjem šuma iz Gaussovog šuma putem naučenog obrnutog procesa. Njihove ključne prednosti su: stabilno uvježbavanje (bez suparničke igre), nema kolapsa modova (ciljna funkcija izravno maksimizira donju granicu log-izglednosti podataka) i konzistentno visoka kvaliteta uzoraka, posebno u smislu distribucijske pokrivenosti. Primarna mana je spora inferencija: standardna DDPM procedura uzorkovanja zahtijeva T sekvencijalnih prolaza unaprijed kroz neuronsku mrežu (tipično $T = 1000$), od kojih je svaki računski zahtjevan. DDIM [18] i drugi ubrzani uzorkovači sveli su to na desetak koraka bez značajnijeg pada kvalitete, ali difuzijski modeli pri inferenciji ostaju sporiji od GAN-ova. Unatoč tomu, prednosti u kvaliteti dovele su do toga da su difuzijski sustavi u velikoj mjeri potisnuli GAN-bazirano generiranje kao preferirani pristup generativnom modeliranju visoke vjernosti [19].

2.2.6. Sinteza

Prirodna putanja područja ukazuje na kombiniranje stabilnih dinamika uvježbavanja visoke kvalitete difuzije s redukcijom dimenzionalnosti koju pruža naučena latentna reprezentacija, što daje latentnu difuzijsku paradigmu koju ovaj rad usvaja. Komprimiranjem ulaza u kompaktan, strukturiran latentni prostor putem VAE-a, postiže se brže

uvježbavanje i inferencija difuzijskog modela.

2.3. Difuzijski modeli: osnove i varijante

Difuzijski probabilistički modeli definiraju dvoprocesni okvir: fiksni unaprijedni proces koji postupno kviri podatke dodavanjem Gaussova šuma, i naučeni obrnuti proces koji iz šuma obnavlja podatke [15]. U ovome odjeljku izlažu se matematičke osnove tog okvira i opisuju se glavne varijante relevantne za ovaj rad.

2.3.1. Unaprijedni proces difuzije

Unaprijedni proces definiran je kao Markovljev lanac indeksiran diskretnim vremenskim korakom $t \in \{1, \dots, T\}$ s fiksnim rasporedom varijance $\{\beta_t\}_{t=1}^T$, gdje $\beta_t \in (0, 1)$. U svakom koraku dodaje se mala količina Gaussovog šuma prethodnom stanju:

$$q(\mathbf{x}_t | \mathbf{x}_{t-1}) = \mathcal{N}(\mathbf{x}_t; \sqrt{1 - \beta_t} \mathbf{x}_{t-1}, \beta_t \mathbf{I}).$$

Ključno svojstvo ovoga Markovljevog lanca jest da se rubna distribucija u bilo kojemu vremenskom koraku t može izraziti u zatvorenoj formi u terminima izvornih podataka $\mathbf{x}_0$. Definirajući $\alpha_t = 1 - \beta_t$ i $\bar{\alpha}_t = \prod_{s=1}^t \alpha_s$, dobiva se:

$$q(\mathbf{x}_t | \mathbf{x}_0) = \mathcal{N}(\mathbf{x}_t; \sqrt{\bar{\alpha}_t} \mathbf{x}_0, (1 - \bar{\alpha}_t) \mathbf{I}).$$

Taj faktorski oblik znači da se $\mathbf{x}_t$ može uzorkovati izravno kao $\mathbf{x}_t = \sqrt{\bar{\alpha}_t} \mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_t} \boldsymbol{\epsilon}$, gdje $\boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$. Kad $t \rightarrow T$, vrijedi $\bar{\alpha}_t \rightarrow 0$ i $\mathbf{x}_T$ konvergira prema otprilike izotropnom Gaussovom šumu, uništavajući sve informacije o $\mathbf{x}_0$.

2.3.2. Obrnuti proces difuzije

Generativni model uči obrnuti proces $q(\mathbf{x}_{t-1} | \mathbf{x}_t)$ koji nije izračunljiv jer zahtijeva integraciju po svim mogućim $\mathbf{x}_0$. Umjesto toga, neuronska mreža $\epsilon_\theta(\mathbf{x}_t, t)$ uvježbava se za aproksimaciju posteriornog središta predviđanjem šuma $\boldsymbol{\epsilon}$ koji je dodan $\mathbf{x}_0$ kako bi se dobio $\mathbf{x}_t$. Parametrizirani obrnuti korak jest:

$$p_\theta(\mathbf{x}_{t-1} | \mathbf{x}_t) = \mathcal{N}(\mathbf{x}_{t-1}; \boldsymbol{\mu}_\theta(\mathbf{x}_t, t), \tilde{\beta}_t \mathbf{I}),$$

gdje se μ_θ izvodi iz predviđanja šuma kao:

$$\mu_\theta(\mathbf{x}_t, t) = \frac{1}{\sqrt{\alpha_t}} \left(\mathbf{x}_t - \frac{1 - \alpha_t}{\sqrt{1 - \bar{\alpha}_t}} \epsilon_\theta(\mathbf{x}_t, t) \right).$$

Ciljna funkcija uvježbavanja, izvedena kao pojednostavljena varijacijska donja granica, svodi se na srednju kvadratnu grešku između stvarnog i predviđenog šuma[15]:

$$\mathcal{L}_{\text{simple}} = \mathbb{E}_{t, \mathbf{x}_0, \epsilon} \left[\left| \epsilon - \epsilon_\theta \left(\sqrt{\bar{\alpha}_t} \mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_t} \epsilon, t \right) \right|^2 \right].$$

2.3.3. Implicitni modeli difuzije s uklanjanjem šuma (DDIM)

Standardno DDPM uzorkovanje zahtijeva prolaz kroz obrnuti Markovljev lanac za svih T vremenskih koraka, što je računski skupno. DDIM [18] reformulira obrnuti proces kao ne-Markovljevu determinističku diferencijalnu nadogradnju, dopuštajući uzorkovanje sa znatno manjim brojem koraka (npr. 50–200) preskakanjem međukoraka. U determinističkoj postavci, DDIM za svaki početni vektor šuma generira jedinstven uzorak, što omogućuje glatku interpolaciju u prostoru šuma i konzistentnu rekonstrukciju.

2.3.4. Rasporedi šuma

Raspored varijance $\{\beta_t\}$ određuje brzinu kojom se informacije uništavaju u naprednom procesu. Intuitivno, izbor niza β_t kontrolira kako $\bar{\alpha}_t = \prod_{s=1}^t (1 - \beta_s)$ pada od 1 do 0, a time i koliko brzo $\mathbf{x}_t$ postaje šum. Izvorni DDPM [15] koristio je linearni raspored od $\beta_1 = 10^{-4}$ do $\beta_T = 0,02$. Naknadno je predložen kosinusni raspored koji glađe prelazi od niskih na visoke razine šuma i za koji je utvrđeno da daje bolje rezultate u zadacima generiranja slika i zvuka, dijelom zato što linearni raspored prenamo uništava informacije pri kraju naprednog procesa.

2.3.5. Latentni difuzijski modeli

Latentni difuzijski modeli (engl. *Latent Diffusion Models*, LDM) [20] uveli su ključan arhitektonski uvid: difuzija ne mora operirati u visokodimenzionalnom prostoru izvornih podataka. Uvježbavanjem perceptualnog autoenkodera za enkodiranje podataka u kompaktan latentni prostor, a zatim uvježbavanjem difuzijskog modela isključivo unu-

tar tog latentnog prostora, LDM-ovi postižu kvalitetu generiranja difuzijskih modela uz manje računalnih troškova. Autoenkoder se uvježbava prvo kombinacijom gubitka rekonstrukcije, perceptualnog gubitka i suparničkog patch-diskriminatora, a potom ostaje fiksiran dok se difuzijski model uvježbava na enkodiranim reprezentacijama. To razdvajanje omogućuje autoenkoderu da zasebno rješava problem perceptualne kompresije (koji zahtijeva podudaranje niskoskalnih struktura signala) od problema generativnog modeliranja (koji zahtijeva modeliranje statističke distribucije semantički smislenih reprezentacija). U U-Net okosnici difuzijskog modela u LDM-ovima inkorporirani su slojevi unakrsne pažnje za uvjetovanje na tekst, oznake klasa ili druge uvjetovne signale, što omogućuje fleksibilno uvjetovanje bez ponovnog uvježbavanja autoenkodera [20].

2.3.6. Uvjetovanje bez klasifikatora

Uvjetovanje bez klasifikatora tehnika je za zamjenu raznolikosti vjerošću u uvjetovanim difuzijskim modelima, primjenjiva kada su dostupne uvjetovne informacije (npr. tekstualni opis ili oznaka klase). Tijekom uvježbavanja, uvjetovni signal nasumično se ispušta s vjerojatnošću p_{uncond} , čime se model uči i uvjetovanom i neuvjetovanom uklanjanju šuma. Pri inferenciji, predviđanje šuma računa se kao

$$\tilde{\epsilon}_{\theta}(\mathbf{x}_t, t, c) = \epsilon_{\theta}(\mathbf{x}_t, t, \emptyset) + w (\epsilon_{\theta}(\mathbf{x}_t, t, c) - \epsilon_{\theta}(\mathbf{x}_t, t, \emptyset)),$$

gdje je c uvjetovni signal, $\emptyset$ označava neuvjetovani slučaj, a $w > 1$ je mjera vođenja koja pojačava uvjetovni smjer.

2.4. Autoenkoderi za učenje latentnog prostora zvuka

Kvaliteta latentne reprezentacije naučene autoenkoderima ključna je za uspjeh naknadnog latentnog difuzijskog modela. U ovome odjeljku pregledavaju se teorijske osnove varijacijskih autoenkodera i praktična razmatranja koja usmjeravaju njihovu primjenu na audio spektrograme.

2.4.1. Standardni autoenkoderi

Standardni (deterministički) autoenkoder sastoji se od enkodera $f_{\phi} : \mathcal{X} \rightarrow \mathcal{Z}$ i dekodera $g_{\theta} : \mathcal{Z} \rightarrow \mathcal{X}$ uvježbanih za minimizaciju gubitka rekonstrukcije $\mathcal{L}_{\text{rec}}(x, g_{\theta}(f_{\phi}(x)))$. Dok

standardni autoenkoderi mogu naučiti kompaktne reprezentacije s malom pogreškom rekonstrukcije, njihov latentni prostor nije strukturiran u odnosu na nikakvu priornu distribuciju: nema jamstva kontinuiranosti (bliske točke u latentnom prostoru ne moraju se dekodirati u perceptualno slične izlaze) ni pokrivenosti (veliki dijelovi latentnog prostora mogu odgovarati nerealističnim podatkovnim točkama). Ta svojstva su problematična za latentno generativno modeliranje, jer generativni model mora naučiti uzorkovati i kretati se latentnim prostorom čiju geometriju nasljeđuje od autoenkodera.

2.4.2. Varijacijski autoenkoder

VAE [12] rješava te probleme zamjenom determinističkog enkodera probabilističkim. Enkoder na izlazu daje parametre Gaussove distribucije nad latentnim kodom:

$$q_{\phi}(\mathbf{z} \mid \mathbf{x}) = \mathcal{N}(\mathbf{z}; \boldsymbol{\mu}_{\phi}(\mathbf{x}), \text{diag}(\boldsymbol{\sigma}_{\phi}^2(\mathbf{x}))),$$

a dekodер $p_{\theta}(\mathbf{x} \mid \mathbf{z})$ preslikava uzorkovane latentne kodove natrag u prostor podataka. Model se uvježbava maksimiziranjem donje granice dokaza (ELBO):

$$\mathcal{L}_{\text{VAE}} = \mathbb{E}_{q_{\phi}(\mathbf{z} \mid \mathbf{x})}[\log p_{\theta}(\mathbf{x} \mid \mathbf{z})] - \beta \cdot D_{\text{KL}}(q_{\phi}(\mathbf{z} \mid \mathbf{x}) \mid \mathcal{N}(\mathbf{0}, \mathbf{I})),$$

gdje je prvi član rekonstrukcijski doprinos, a drugi KL divergencija između posteriornog enkodera i unitarnog Gaussovog priora. Uzorkovanje iz enkodera pri uvježbavanju koristi trik reparametrizacije, $\mathbf{z} = \boldsymbol{\mu} + \boldsymbol{\sigma} \odot \boldsymbol{\epsilon}$ s $\boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$, koji omogućuje tok gradijenta kroz stohastički korak uzorkovanja.

2.4.3. β -VAE

β -VAE [21] uvodi skalarnu težinu $\beta > 1$ na KL članu, povećavajući pritisak na enkoder da odgovori prioru i time potičući latentni prostor da bude više razvezanog karaktera, tj. da pojedinačne latentne dimenzije odgovaraju neovisnim generativnim faktorima varijacije u podacima. Međutim, povećanje β dolazi po cijenu kvalitete rekonstrukcije, jer stroži KL uvjet ograničava količinu informacija koju enkoder može zadržati o ulazu. U kontekstu ovoga rada, odabir β određuje kompromis između vjernosti VAE rekonstrukcije, što je preduvjet za perceptualno prihvatljiv audio izlaz, i regularnosti latentnog prostora, što je preduvjet za stabilno uvježbavanje difuzije.

2.4.4. Kolaps posteriora

Poznati kvar VAE-a jest kolaps posteriora [13], u kojemu dekodер postane dovoljno snažan da rekonstruira ulaz iz latentnog koda s vrlo malo informacija, nakon čega enkoder više nema poticaj enkodirati smislene informacije, a KL doprinosi po dimenzijama kolabiraju na nulu. U tom degeneriranom stanju aproksimativni posterior praktički je jednak prioru, ali latentni prostor ne nosi nikakve informacije o ulazu, čineći ga beskorisnim kao generativnu reprezentaciju. Detekcija se oslanja na praćenje KL vrijednosti po dimenzijama tijekom uvježbavanja: dimenzije s KL-om bliskim nuli smatraju se kolabiranim. Strategije ublažavanja uključuju žarenje KL termina (engl. *KL annealing*, početak s $\beta \approx 0$ i postupno povećavanje), korištenje manje snažnog dekodera te regularizaciju slobodnih bita, koja zanemaruje KL doprinos dimenzija ispod zadanog praga informacijske stope.

2.4.5. Konvolucijski VAE za spektrograme

Za mel spektrograme najprirodniji arhitektonski odabir jest konvolucijski VAE. Enkoder se sastoji od stoga konvolucijskih slojeva s podnabiranjem (engl. *strided convolutions*) koji postupno podnabiru dvodimenzijski spektrogram duž frekvencijske i vremenske osi, proizvodeći prostornu kartu obilježja. Ta se karta zatim završnim konvolucijskim slojem projicira u vektore srednjih vrijednosti i log-varijanci. Dekoder zrcali tu strukturu transponiranim konvolucijskim slojevima ili nadabiranjem najbližeg susjeda praćenim konvolucijama, čime se vraća na izvorne dimenzije spektrograma. Ključni odabiri dizajna uključuju broj enkoderskih i dekoderskih stadija te pripadne faktore podnabiranja, dubinu kanala na svakom stadiju, korištenje grupne ili batch normalizacije te dimenzionalnost C latentne kanalne dimenzije. Ukupna latentna dimenzionalnost jest $C \times H' \times W'$, gdje su H' i W' prostorne dimenzije latentne karte nakon enkodiranja.

2.4.6. Neuronski audio kodeci

Neuronski kodeci poput EnCodec-a [5] uče diskretne latentne reprezentacije putem kvantizacije vektora. Dok su diskretne reprezentacije prednost za autoregresivne jezične modele, kontinuirani VAE latentni prirodniji su za kontinuirani Gaussov proces uklanjanja šuma difuzijskih modela. Pretvorba između diskretnih i kontinuiranih reprezentacija zahtijeva dodatne korake modeliranja, te je stoga u ovome radu usvojen pristup konti-

nuiranih latentnih difuzija u stilu LDM-ova [20].

2.4.7. Praktični aspekti VAE-a za mel spektrograme

U praksi je normalizacija ulaznog mel spektrograma ključna: log-mel vrijednosti obuhvaćaju širok dinamički raspon, a standardizacija ulaza (oduzimanje srednje vrijednosti skupa za uvježbavanje i dijeljenje standardnom devijacijom) značajno stabilizira VAE uvježbavanje. Nadopunjavanje rekonstrukcijskog gubitka po uzorku spektralnim gubitkom, primjerice višerezolucijskim STFT gubitkom korištenim u neuronskim vokoderima [8], može poboljšati perceptualnu kvalitetu rekonstrukcija penaliziranjem modela za greške u frekvencijskoj domeni koje bi mogle biti nevidljive mjerama po uzorku. Enkodiranje cijelog niza u odnosu na enkodiranje temeljem zakrpa još je jedan odabir dizajna: enkodiranje cijelog spektrograma jednim konvolucijskim stogom jednostavnije je i bolje zahvaća globalnu strukturu, dok enkodiranje temeljem zakrpa (tretiranje spektrograma kao mreže zakrpa fiksne veličine) može biti prikladnije za vrlo dugačke audio sekvence koje premašuju memoriju GPU-a.

2.5. Latentni difuzijski modeli za generiranje glazbe

Latentna difuzijska paradigma primijenjena je na generiranje zvuka i glazbe u nizu sve sposobnijih sustava. Ovaj odjeljak pregledava radove koji su izravno relevantni za ovaj pristup, razmatrajući svaki od glavnih sustava zasebno, a zatim pozicionira ovaj rad u odnosu na njih.

2.5.1. AudioLDM

AudioLDM [22] bio je među prvim sustavima koji su primijenili latentne difuzijske modele na generiranje zvuka. VAE se uvježbava za enkodiranje mel spektrograma u kompaktan kontinuirani latentni prostor, a difuzijski model utemeljen na U-Net arhitekturi uvježbava se u tom latentnom prostoru, uvjetovan na audio-tekstualne ugrađene reprezentacije izvedene iz CLAP-a [23], kontrastivnog audio-jezičnog modela uvježbavanog za usklađivanje tekstualnih i akustičkih reprezentacija. Pri inferenciji tekstualni opis enkodira CLAP tekstualni enkoder i koristi se za uvjetovanje difuzijskog modela putem unakrsne pažnje. AudioLDM je pokazao da se generiranje zvuka iz teksta može postići

s kvalitetom i učinkovitošću usporedivima s latentnim difuzijskim modelima u domeni slike. Sustav je primarno dizajniran i evaluiran za opći zvuk (zvukovi okoline, govor, glazba), a njegova sposobnost generiranja glazbe bila je ograničena širinom cilja uvježbavanja.

2.5.2. MusicLDM

MusicLDM [24] proširuje AudioLDM specifično na glazbu. Arhitektura je slična: VAE enkodira mel spektrogram, a difuzijski model utemeljen na U-Net arhitekturi djeluje u latentnom prostoru i uvjetovan je na CLAP ugrađene reprezentacije. MusicLDM uvodi strategiju augmentacije mješavine sinkronizirane s udarcem, primijenjenu i na razini latentne reprezentacije i na razini CLAP uvjetovanja. Ta augmentacija, koja stvara nove primjere uvježbavanja miješanjem latentnih kodova i uvjetovnih signala iz različitih glazbenih isječaka na granicama udaraca, služi i kao tehnika proširenja podataka i kao mehanizam za smanjenje rizika od memoriranja i doslovnog reproduciranja materijala za uvježbavanje. MusicLDM je evaluiran na skupu podataka MusicCaps i pokazao je poboljšanu kvalitetu na testovima slušanja specifičnim za glazbu u usporedbi s AudioLDM-om.

2.5.3. Multi-Track MusicLDM

Multi-Track MusicLDM (MT-MusicLDM) [25] proširuje MusicLDM na višekanalni, višestazni generativni model. Umjesto izravnog generiranja pune glazbene mješavine, model uči zajedničku distribuciju vjerojatnosti više instrumentalnih staza koje dijele isti glazbeni kontekst. Arhitektura zadržava iste temeljne komponente kao MusicLDM: VAE, difuzijski model utemeljen na U-Net arhitekturi i CLAP enkoder za uvjetovanje. U-Net je dodatno proširen trodimenzionalnim konvolucijama kako bi mogao istovremeno obrađivati višekanalne latentne reprezentacije svih staza.

2.5.4. Stable Audio

Stable Audio [26] skalira latentne difuzijske modele na visokokvalitetno stereo generiranje glazbe pri 44,1 kHz, sposobno generirati skladbe duljine nekoliko minuta. Autoenkoder operira izravno na stereo valnom obliku, a ne na mel spektrogramima, koristeći

konvolucijski enkoder koji generira kontinuiranu latentnu reprezentaciju pri reduciranoj vremenskoj frekvenciji. Ključna inovacija jest uvođenje vremenskog uvjetovanja: pri uvježbavanju modelu se daje vrijeme početka i ukupno trajanje svakog audio isječka, što mu omogućuje učenje generiranja zvuka koji je koherentan kroz dulje vremenske rasponne te specificiranje željenog trajanja pri inferenciji. Stable Audio je uvježban na velikom vlasničkom skupu podataka licencirane glazbe te evaluiran objektivnim metrikama i velikim testovima slušanja.

2.5.5. Moûsai

Moûsai [27] rješava izazov visokofidelnog stereo generiranja glazbe pri 48 kHz kroz dvostupanjsku kaskadnu difuzijsku arhitekturu. Model prvog stupnja generira niskofrekvencijsku latentnu reprezentaciju pri znatno reduciranoj frekvenciji uzorkovanja, uvjetovanu tekstualnim upitima i zahvaćajući grubu glazbenu strukturu. Model drugog stupnja zatim generira visokofrekventni, visokofidelan stereo signal uvjetovan na izlaz prvog stupnja. Taj kaskadni pristup razdvaja generiranje grube glazbene strukture od sinteze finoizrađene akustičke detalje te proizvodi izlaze s jakom glazbenom koherencijom kroz dulje vremenske skale.

2.5.6. Difuzijsko-transformerska arhitektura

Difuzijsko-transformerska arhitektura predstavljena u radu *Long-form music generation with latent diffusion* [28], zamjenjuje U-Net okosnicu transformerom i djeluje na agresivno podnabranim audio latentima pri vrlo niskoj latentnoj vremenskoj frekvenciji od otprilike 21,5 Hz. Ta ekstremna vremenska kompresija omogućuje modelu generiranje koherentne glazbe na ljestvici cijele pjesme, do približno četiri minute i četrdeset pet sekundi, unutar upravljivog trajanja niza za mehanizam pažnje transformera. Rad pokazuje da arhitektonski odabiri vezani uz stopu latentne kompresije imaju odlučujući utjecaj na postizivo trajanje generiranja i strukturnu koherenciju.

2.5.7. Pozicioniranje ovog rada

Ovaj se rad razlikuje od gore navedenih sustava u nekoliko važnih aspekata. Opseg mu je znatno manji: skup podataka za uvježbavanje čini 150 skladbi sadržanih u MUSDB18

skupu, nasuprot desecima tisuća skladbi korištenih u komercijalnim sustavima navedenima ranije. Zadatak je neuvjetovano generiranje, što iz sustava uklanja cjevovod tekstualnog uvjetovanja i s njim povezane velike prethodno uvježbane modele (CLAP i slične). Fokus je eksplicitno na dizajnu cjevovoda, metodologiji evaluacije i sustavnom proučavanju specifičnih odabira dizajna, a ne na maksimiziranju kvalitete generiranja na velikom opsegu. Takav odabir opsega čini rad izvedivim unutar resursnih ograničenja akademskog okruženja uz zadržavanje izravne veze s granicama istraživačkog područja.

2.6. Skupovi podataka za generiranje glazbe

Odabir skupa podataka za uvježbavanje ima velik utjecaj na generativnu sposobnost i protokol evaluacije svakog sustava za generiranje glazbe. Ovaj odjeljak opisuje skupove podataka najrelevantnije za ovaj rad i opravdava odabir MUSDB18 kao primarnog skupa podataka za uvježbavanje.

2.6.1. MUSDB18

MUSDB18 [29] je skup podataka od 150 profesionalno snimljenih i miksanih glazbenih skladbi, koji se sastoji od 100 skladbi za uvježbavanje i 50 za testiranje, sve pri 44,1 kHz u stereo formatu. Svaka je skladba dostupna u Native Instruments STEMS formatu, koji enkodira četiri izolirana instrumentalna stabla: bubnjeve, bas, ostale (melodijske instrumente) i vokale, uz potpuni miks. Skup podataka izvorno je prikupljen za Kampanju evaluacije razdvajanja signala (SiSEC 2018) i od izdavanja služi kao standardna referentna točka za razdvajanje glazbenih izvora. Pokriva širok raspon žanrova, uključujući pop, rock, jazz i elektroničku glazbu.

Za potrebe ovoga rada koristi se isključivo puni miks, pri čemu se svaka skladba tretira kao neuvjetovani primjer za uvježbavanje u generiranju glazbe. Korištenje MUSDB18 za neuvjetovano generiranje, umjesto za namijenjeni zadatak razdvajanja, opravdano je profesionalnom kvalitetom snimke, žanrovskom raznolikošću, utvrđenim zajedničkim alatima za predprocesiranje (primjerice torchaudio i stempeg) te činjenicom da pruža dobro razumljiv, javno dostupan skup podataka za koji je usporedba različitih eksperimentalnih konfiguracija izravna. Nužno je uvažiti jedno značajno praktično ograničenje: sto skladbi za uvježbavanje vrlo je mali korpus prema standardima suvremenog

generativnog modeliranja.

2.6.2. MusicCaps

MusicCaps [30] je skup podataka od otprilike 5 000 desetosekundnih audio isječaka iz AudioSet korpusa, pri čemu je svaki anotiran prirodno-jezičnim tekstualnim opisom glazbenog sadržaja (instrumenti, žanr, raspoloženje, tempo itd.) te skupom strukturiranih opisnih oznaka. MusicCaps je objavljen uz model MusicLM i od tada je postao standardna referentna točka za evaluaciju generiranja glazbe uvjetovanog tekstom. U ovome radu ne koristi se kao skup podataka za uvježbavanje jer se rad bavi neuvjetovanim generiranjem, a AudioSet isječki su ograničeni na deset sekundi te ne moraju predstavljati glazbenu strukturu punih duljina relevantnu za ovaj rad.

2.6.3. Free Music Archive

Free Music Archive (FMA [31]) velika je zbirka javno licenciranih glazbenih skladbi, pri čemu puni skup podataka sadrži otprilike 100 000 skladbi koje obuhvaćaju 161 žanr. Podskupovi FMA-small i FMA-medium (8 000 i 25 000 skladbi) uobičajeno se koriste kao skupovi podataka za uvježbavanje u istraživanju generiranja glazbe. FMA nudi veću raznolikost i obujam u usporedbi s MUSDB18 te bi bio prikladan odabir za skaliranu verziju sustava predloženog u ovome radu.

2.7. Evaluacija generativnih audio modela

Evaluacija generativnih audio modela predstavlja jedinstvene metodološke izazove. Za razliku od diskriminativnih zadataka poput klasifikacije ili segmentacije izvora, gdje je za svaki ulaz dostupna referenca, neuvjetovano generiranje ne proizvodi uparene parove izlaza i referenci. Zadatak je generirati zvuk koji plauzibilno pripada istoj distribuciji kao i skup za uvježbavanje, a evaluacija stoga mora operirati na distribucijskoj razini, uspoređujući statistička svojstva generiranih i stvarnih skupova zvuka, a ne pojedinačne uzorke. Ovaj odjeljak pregledava glavne evaluacijske metrike korištene u istraživačkom području i specificira njihovu ulogu u ovome radu.

2.7.1. Fréchetova audio udaljenost

Fréchetova audio udaljenost (engl. *Fréchet Audio Distance*, FAD) [32] najšire je korištena automatska evaluacijska metrika za generativne audio modele. Prilagođena je iz Fréchetove udaljenosti inepcije (FID) korištene u generiranju slika: zvuk iz generiranog skupa i referentnog skupa provlači se kroz fiksnu prethodno uvježbanu mrežu za ugrađivanje zvuka, a dobiveni vektori ugrađivanja modeliraju se kao multivarijatne Gaussove distribucije. FAD se zatim računa kao Fréchetova udaljenost između tih dviju Gaussovih distribucija:

$$\text{FAD} = \|\mu_r - \mu_g\|^2 + \text{Tr}\left(\Sigma_r + \Sigma_g - 2(\Sigma_r \Sigma_g)^{1/2}\right),$$

gdje su (μ_r, Σ_r) i (μ_g, Σ_g) srednje vrijednosti i kovarijance distribucija ugrađivanja stvarnog i generiranog skupa. Niža FAD ukazuje da je generirana distribucija bliža stvarnoj distribuciji u prostoru ugrađivanja. Pokazano je da FAD korelira s ljudskim perceptualnim ocjenama [32], iako je korelacija umjerena i varira s korištenim modelom ugrađivanja. Uobičajeni modeli ugrađivanja za FAD glazbe uključuju VGGish [33] te CLAP [23] i MERT [34]. Odabir modela ugrađivanja značajno utječe na numeričke vrijednosti FAD-a, čineći usporedbe između radova nepouzdanima osim ako nije korišten isti model ugrađivanja, što je istaknuto i u radu SongEval [35]. FAD također pati od pristranosti uzorkovanja analogne FID-u: s malim evaluacijskim skupovima, Gaussova aproksimacija nije pouzdana i procjene FAD-a imaju visoku varijancu.

2.7.2. Kernelska audio udaljenost

Kernelska audio udaljenost (engl. *Kernel Audio Distance*, KAD) [36] alternativa je FAD-u temeljena na jezgri koja izbjegava pretpostavku Gaussovske distribucije korištenjem okvira maksimalnog srednjeg kvadratnog odstupanja jezgre. U literaturi se argumentira da KAD rješava neke patološke načine ponašanja FAD-a pri malim veličinama uzorka te da je statistički bolje kalibriran. U praksi je manje prihvaćen od FAD-a, ali predstavlja važnu metodološku alternativu.

2.7.3. Srednja ocjena mišljenja

Srednja ocjena mišljenja [37] (engl. *Mean Opinion Score*, MOS) standard je subjektivne evaluacijske metrike za kvalitetu zvuka. Ljudskim se slušačima prikazuju kratki audio

isječci, a od njih se traži da ocijene prirodnost, glazbenost ili ukupnu kvalitetu na Likertovoj skali od pet stupnjeva; MOS je srednja vrijednost tih ocjena po slušačima i isječcima. Dobre prakse za MOS testove slušanja uključuju dovoljan broj slušača (tipično najmanje dvadeset za statistički pouzdane procjene), pažljiv odabir isječaka koji su reprezentativni za punu distribuciju generiranja, uključivanje sidrenih podražaja (referenci poznate kvalitete) za kalibraciju te uravnotežen redoslijed prezentacije kako bi se minimizirali efekti redoslijeda.

2.7.4. MUSHRA

MUSHRA [38] (engl. *MU*ltiple *S*timuli with *H*idden *R*eference and *A*ncor) test je subjektivne usporedbe u kojemu slušači ocjenjuju višestruke izlaze sustava u odnosu na skrivenu referencu na kontinuiranoj skali od 0 do 100, uz uključenu niskokvalitetnu sidrenu točku za kalibraciju skale. MUSHRA je posebno prikladan za kontrolirane usporedbe varijanti sustava, jer sve sustave postavlja u izravnu konkurenciju unutar jednog testa slušanja i smanjuje međusubjektivnu varijabilnost u odnosu na paradigme apsolutnog ocjenjivanja.

2.7.5. Spektralne metrike

Spektralni deskriptori [39] pružaju interpretabilne dijagnostike specifičnih svojstava boje i ritma generiranog zvuka. Razmatraju se četiri deskriptora: spektralni centroid (središte mase spektralne magnitude), spektralna ravnoća (mjera sličnosti spektra bijelome šumu nasuprot tonalnom signalu), spektralni odrez (frekvencija ispod koje je koncentriran zadani udio ukupne spektralne energije) te spektralni fluks (mjera gustoće ritmičkih događaja). Navedeni deskriptori nisu perceptualne metrike i ne predviđaju izravno ljudske ocjene kvalitete, ali su korisni za prepoznavanje sustavnih kvarova. Primjerice, generirani skup s anomalno visokom spektralnom ravnoćom može ukazivati na to da model generira izlaze nalik na šum, dok niski spektralni fluks može ukazivati na odsutnost ritmičke strukture.

2.7.6. Metrike na razini signala

Metrike poput omjera signal-šum (engl. *Signal-to-Noise Ratio*, SNR), omjera signal-distorzija (engl. *Signal-to-Distortion Ratio*, SDR) i mel-kepstralne distorzije (engl. *Mel Cepstral Dis-*

tortion, MCD) prikladne su za evaluaciju generiranog zvuka, ako je dostupan referentni valni oblik s kojim se generirani signal uspoređuje. Nisu prikladne za evaluaciju kvalitete neuvjetovanog generiranja, budući da referentni signal u tome slučaju nije dostupan.

2.7.7. Pregled evaluacijskih metrika

Tablica 2.1. Metrike evaluacije generativnih audio modela

Metrika	Vrsta		Primjena
Fréchetova audio udaljenost (FAD)	Objektivna,	distribucij-ska razina	Procjena kvalitete generiranih uzoraka na razini distribucije
Kernelska audio udaljenost (KAD)	Objektivna,	distribucij-ska razina	Unakrsna provjera nalaza FAD-a
Spektralni centroid, ravnoća, odrez	Objektivna,	razina signala (populacijska statistika)	Dijagnostika tembralnih svojstava generiranog zvuka
Spektralni fluks	Objektivna,	razina signala (populacijska statistika)	Dijagnostika ritmičke strukture generiranog zvuka
Omjer signal-distorzija (SDR)	Objektivna,	razina signala (referentna)	Procjena kvalitete rekonstrukcije VAE-a
Mel-kepstralna distorzija (MCD)	Objektivna,	razina signala (referentna)	Procjena spektralne vjernosti rekonstrukcije VAE-a
Srednja ocjena mišljenja (MOS)	Subjektivna		Perceptualna procjena kvalitete generiranih uzoraka
MUSHRA	Subjektivna		Kontrolirana usporedba kvalitete generiranih uzoraka

3. Opis problema i programsko ostvarenje

Ovo poglavlje donosi detaljan implementacijski opis sustava za bezuvjetno generiranje glazbe temeljen na difuzijskom modelu u latentnom prostoru. Nakon preciznog opisa zadatka i skupa podataka, prikazan je pregled cjelokupne dvofazne arhitekture, korištene tehnologije te svi koraci od sirovih audio datoteka do generiranog zvučnog isječka. Srž poglavlja čine opisi varijacijskog autoenkodera (poglavlje 3.6.) i difuzijskog modela (poglavlje 3.7.), koji zajedno tvore predloženi sustav.

3.1. Opis problema

3.1.1. Definicija zadatka i ograničenja

Zadatak koji se rješava u ovom radu jest bezuvjetno generiranje glazbe (engl. *unconditional music generation*): sustav treba biti sposoban sintetizirati kratke glazbene isječke koji zvukom nalikuju glazbenim zapisima iz skupa za učenje, bez ikakvog ulaznog uvjetnog signala poput tekstualnog opisa, melodijskog predloška ili oznake žanra. Ulaz u cijeli sustav jest skup audio datoteka, a izlaz su novo generirani WAV zapisi trajanja desetak sekundi.

Ograničenja sustava mogu se razvrstati u nekoliko kategorija:

- **Računalna ograničenja.** Treniranje dubokih generativnih modela zahtjevano je po pitanju memorije grafičke kartice i računalnog vremena. Kako bi se smanjio teret obrade, audio signal se snižava na frekvenciju uzorkovanja od 5 512 Hz (umjesto standardnih 44,1 kHz), čime se trajanje dulje od 10 sekundi svodi na tek 55 120 uzoraka. Ova kompromisna odluka smanjuje spektralnu razlučivost, ali čini model praktično izvedivim na raspoloživoj strojnoj opremi.

- **Ograničenje trajanja.** Sustav je projektiran za isječke fiksnog trajanja od 10 sekundi. Duži audio zapisi rezanjem se svode na isječke te duljine; isječci kraći od zadane duljine ne uzimaju se u obzir (ostatak se odbacuje metodom cjelobrojnog dijeljenja).
- **Bezuvjetnost generiranja.** Generiranje je isključivo stohastičko, vođeno naučenom distribucijom latentnih vektora mel-spektrograma.
- **Reprezentacija zvuka.** Sustav ne radi izravno s valnim oblicima, već s log-mel spektrogramima, koji su kompaktna i perceptivno motivirana reprezentacija audio signala. Inverzna pretvorba iz spektrograma u valni oblik provodi se Griffin-Lim algoritmom [7], koji ne zahtijeva dodatnu neuronsku mrežu (za razliku od vokodera [8]), ali unosi određenu artefaktualnu boju zvuka.
- **Mono signal.** Unatoč tome što su originalne snimke stereo, za potrebe ovog sustava signal se prevodi u mono, čime se smanjuje dimenzionalnost ulaznog tenzora i pojednostavljuje arhitektura.

Opisani kompromisi dio su dizajnerske odluke kojom se prednost daje istraživačkoj izvedivosti nad komercijalnom kvalitetom generiranog zvuka.

3.1.2. Skup podataka MUSDB18

Za učenje i vrednovanje sustava koristi se skup podataka MUSDB18 [29], standardni repozitorij za istraživanje razdvajanja glazbenih instrumenata (music source separation). Skup sadrži 150 profesionalno snimljenih višekanalnih glazbenih skladbi: 100 skladbi namijenjenih učenju i 50 skladbi za ispitivanje.

Svaka je skladba pohranjena u obliku višekanalne `.stem.mp4` audio datoteke. Sadrži pet zasebnih zvučnih kanala (engl. *stems*):

- `stem 0`: mixture (potpuna mješavina)
- `stem 1`: drums (bubnjevi i udaraljke)
- `stem 2`: bass (bas-gitara)
- `stem 3`: other (ostali instrumenti)

- stem 4: vocals (vokali)

Izvorna uzorkovna frekvencija iznosi 44,1 kHz, a snimke su stereo. Za potrebe ovog rada koristi se isključivo stem 0 (potpuna mješavina), koji predstavlja finalni zvučni zapis cijele skladbe. Time se postiže raznolik i muzikalno smisleni skup uzoraka koji obuhvaća različite žanrove (pop, rock, jazz, elektronska glazba i dr.), instrumente i produkcijske stilove.

U fazi učenja difuzijskog modela koriste se sve 150 skladbe, dok se VAE trenira na manjem podskupu skladbi radi bržeg razvoja i validacije arhitekture.

3.2. Predloženo rješenje: pregled sustava

Predloženi sustav temelji se na dvofaznoj arhitekturi koja razdvaja problem generiranja glazbe na dvije međuoavisne, ali odvojeno trenirane komponente, slično pristupu Latent Diffusion Models (LDM) [20].

Prva faza obuhvaća treniranje varijacijskog autoenkodera (engl. *Variational Autoencoder*, VAE). VAE uči preslikati visokodimenzionalne log-mel spektrograme (tenzori dimenzije $(1, 80, W)$) u kompaktan, regulariziran latentni prostor dimenzije $(16, H/8, W/8)$, tj. s faktorom prostorne kompresije $8\times$. Time se složena audio reprezentacija prevodi u manji, latentni vektor na kojemu difuzija može djelovati znatno efikasnije nego na izvornoj spektrogramskoj razlučivosti.

Druga faza obuhvaća treniranje difuzijskog modela u latentnom prostoru. Ulazi se posteriornom sredinom latentnog vektora iz zamrznutog VAE enkodera, a U-Net denoiser uči invertirati proces postupnog dodavanja Gaussovog šuma u tom prostoru. Za generiranje novog glazbenog isječka dovoljan je jednokratni uzorak Gaussovog šuma koji prolazi kroz naučeni obrnuti difuzijski proces, nakon čega VAE dekoder transformira dobiveni latentni vektor natrag u mel-spektrogram, a Griffin-Lim algoritam [7] prevodi spektrogram u WAV datoteku.

Ključna prednost ovakve arhitekture jest da difuzijski model operira nad latentnim prostorom koji je za faktor $8^2 = 64$ manji (po ukupnom broju elemenata) od izvornog mel-spektrograma, što smanjuje računalni trošak difuzijskih koraka.

3.3. Korištene tehnologije i knjižnice

Sustav je implementiran u programskom jeziku Python 3.14, a za definiciju i treniranje neuronskih mreža koristi se okvir PyTorch [40]. Tablica 3.1. donosi pregled svih korištenih knjižnica s kratkim opisom namjene.

Tablica 3.1. Pregled korištenih Python knjižnica.

Knjižnica	Namjena
torch	Definicija mreža, automatsko deriviranje, GPU izvršavanje
torchaudio	Čitanje i pisanje WAV datoteka
librosa	Izračun mel-spektrograma, Griffin-Lim inverzija
stempeg	Čitanje .stem.mp4 datoteka (MUSDB18 format)
numpy	Numerički izračuni, statistike normalizacije
matplotlib	Vizualizacija spektrograma i histograma
tqdm	Prikaz napretka (<i>progress bar</i>) pri treniranju

Arhitekture VAE-a i difuzijskog modela definirane su kao `torch.nn.Module` podklase. Treniranje se provodi na grafičkoj kartici uz korištenje standardnog PyTorch mehanizma. Sve operacije konvolucije, normalizacije i aktivacijskih funkcija pozivaju se iz `DataLoader` `torch.nn` i `torch.nn.functional` modula. Analiza i sinteza audio signala provode se isključivo knjižnicom `librosa`, dok `torchaudio` služi za ulazno-izlazne operacije nad WAV datotekama.

3.4. Računalni resursi

Svi eksperimenti provedeni su na prijenosnom računalu s grafičkom karticom NVIDIA GeForce RTX 4050 (6 GB VRAM, CUDA 13.0), procesorom AMD Ryzen 5 7535HS (6 jezgri, 12 dretvi, do 4,55 GHz) te 16 GB radne memorije.

3.5. Obrada podataka

Priprema podataka odvija se u tri koraka: izvoz mješavina iz višekanalnih .stem.mp4 datoteka, rezanje WAV zapisa na isječke fiksnog trajanja te pretvorba u mel-spektrogramsku reprezentaciju pogodnu za ulaz u VAE.

3.5.1. Izvoz mješavina iz MUSDB18

Svaka `.stem.mp4` datoteka čita se knjižnicom `stempeg`, koja omogućava selektivno dekodiranje pojedinih kanala višekanalnog zapisa. Pozivom funkcije `stempeg.read(path, stem_id=0)` dohvaća se isključivo `stem 0` (potpuna mješavina). Rezultirajući signali stereo formata pri uzorkovnoj frekvenciji 44 100 Hz zapisuju se kao WAV datoteke u hijerarhijsku strukturu direktorija:

`output_dir/{train,test}/{TrackName}/mixture.wav`

Ovaj korak provodi se jednom kao predobrada (engl. *preprocessing*), a nastale datoteke koriste se u svim daljnjim fazama učenja i inferencije.

3.5.2. Rezanje na isječke

Budući da su originalne skladbe duljine reda veličine od dvije do pet minuta, a model je projektiran za obradu isječaka trajanja $T = 10$ s, svaka `mixture.wav` datoteka reže se na isječke zadane duljine. Rezanje se provodi cjelobrojnim dijeljenjem ukupnog broja uzoraka s brojem uzoraka po isječku, a ostatak (nedovoljno dug završni fragment) se odbacuje. Time se osigurava strogo jednaka duljina svakog isječka:

$$N_{\text{chunks}} = \left\lfloor \frac{L_{\text{total}}}{T \cdot f_s} \right\rfloor$$

gdje je L_{total} ukupan broj uzoraka u datoteci, $T = 10$ s i $f_s = 44\,100$ Hz.

Nastali isječci čuvaju se u mapi `chunks_10/` unutar mape odgovarajuće skladbe, s imenima oblika `chunk_XXXX.wav`, gdje `XXXX` označava redni broj isječka s vodećim nulama.

3.5.3. Mel-spektrogramska reprezentacija i normalizacija

Učitavanje i transformacija isječaka provode se klasom `MelDataset`, koja implementira sučelje `torch.utils.data.Dataset`. Svaki isječak obrađuje se prema sljedećem nizu koraka:

1. Isječak se učitava i pretvara u mono signal te ponovo uzorkuje na $f_s = 5\,512$ Hz (sniženo radi računalne efikasnosti). Time 10-sekundni isječak sadrži točno $N_{\text{samples}} = 55\,120$ uzoraka.
2. Isječci kraći od N_{samples} dopunjavaju se nulama. Isječci dulji od N_{samples} izrezuju se na nasumičnom pomaku. Time svi uzorci ulaze u mrežu s identičnom duljinom.
3. Mel-spektrogram računa se pozivom `librosa.feature.melspectrogram` s parametrima:

$$N_{\text{FFT}} = 1\,024, \quad H_{\text{hop}} = 256, \quad N_{\text{mels}} = 80.$$

Rezultirajuća matrica dimenzije $(80, W)$ predstavlja snagu u 80 mel-filtera kroz W vremenskih okvira, pri čemu je $W = \lfloor N_{\text{samples}}/H_{\text{hop}} \rfloor + 1 = \lfloor 55\,120/256 \rfloor + 1 = 215 + 1 = 216$.

4. Snaga se pretvara u decibelsku skalu normiranu prema maksimumu isječka:

$$S_{\text{dB}} = 10 \log_{10} \left(\frac{S}{\max(S)} \right),$$

implementirano kao `librosa.power_to_db(mel, ref=np.max)`, čime su svi elementi u rasponu $(-\infty, 0]$ dB.

5. Normalizacija u $[0, 1]$. Budući da u praksi mel-spektrogrami rijetko imaju vrijednosti ispod -80 dB, primjenjuje se linearna normalizacija:

$$S_{\text{norm}} = \frac{S_{\text{dB}} + 80}{80},$$

nakon čega se vrijednosti obrezuju na segment $[0, 1]$ i pretvaraju u tip `float32`.

6. Prostorno dopunjavanje. Kako VAE sadrži tri razine poduzorkovanja s faktorom $2\times$, prostorna dimenzija mora biti djeljiva s $M = 8$. Vremenski broj okvira W dopunjuje se nulama s desna do najbližeg višekratnika od 8: $W' = \lceil W/8 \rceil \cdot 8$.
7. Finalni tenzor oblika $(1, 80, W')$ predstavlja jednokanalni prikaz mel-spektrograma pogodnu za konvolucijsku obradu.

Primijenjeni parametri sažeti su u tablici 3.2.

Tablica 3.2. Parametri mel-spektrogramske pretvorbe.

Parametar	Vrijednost	Opis
SAMPLE_RATE	5 512 Hz	Uzorkovna frekvencija nakon ponovnog uzorkovanja
N_SAMPLES	55 120	Broj uzoraka po isječku ($10\text{ s} \times 5\,512$)
N_FFT	1 024	Veličina FFT prozora
HOP_LENGTH	256	Korak između prozora
N_MELS	80	Broj mel-filtera
MEL_TIME_DIVISOR	8	Djelitelj za prostorno dopunjavanje

3.6. Varijacijski autoenkoder

Varijacijski autoenkoder (VAE) [12] predstavlja prvu fazu sustava. Njegova uloga je dvos-truka: komprimirati mel-spektrogram u kompaktan latentni vektor i osigurati da la-tentni prostor bude dovoljno regulariziran (blizak standardnoj normalnoj distribuciji) kako bi difuzijski model mogao naučiti koherentnu distribuciju nad njim.

3.6.1. Arhitektura enkodera i dekodera

Osnovna gradivna jedinica i enkodera i dekodera jest rezidualni blok (*ResBlock*) [41]. Blok transformira ulazni tenzor $\mathbf{x}$ s C_{in} kanala u izlaz s C_{out} kanala prema sljedećoj shemi:

$$\mathbf{h} = \sigma(\text{GN}(\text{Conv}_{3 \times 3}(\mathbf{x}))), \quad \mathbf{h}' = \text{GN}(\text{Conv}_{3 \times 3}(\mathbf{h})), \quad \text{izlaz} = \sigma(\mathbf{h}') + \text{skip}(\mathbf{x}),$$

gdje je σ aktivacijska funkcija SiLU (*Sigmoid Linear Unit*, $\sigma(x) = x \cdot \text{sigmoid}(x)$) [41] i GN označava grupnu normalizaciju (*GroupNorm*) [42]. Skip veza skip je projekcijska konvolucija 1×1 ako se broj kanala mijenja ($C_{\text{in}} \neq C_{\text{out}}$), a u suprotnom je identiteta. Važno je napomenuti da se SiLU aktivacija primjenjuje na izlaz konvolucijske grane prije pribrajanja skip veze, čime se sprječava dominacija identitetske veze nad naučenom tran-sformacijom.

Enkoder prima ulazni tenzor oblika $(B, 1, H, W)$ i provodi ga kroz niz konvolucijskih slojeva s postupnim povećanjem broja kanala i smanjenjem prostorne razlučivosti. Ar-hitektura se može prikazati tablično:

Nakon triju slojeva poduzorkovanja s korakom 2 prostorne dimenzije smanjuju se za faktor $8\times$ u svakoj dimenziji, pa izlazni latentni tenzori $\boldsymbol{\mu}$ i $\log \sigma^2$ imaju oblik $(B, 16, H/8, W/8)$.

Dekoder prima latentni uzorak $\mathbf{z}$ oblika $(B, 16, H/8, W/8)$ i rekonstruira mel-spektrogram:

Tablica 3.3. Sekvencijalna arhitektura VAE enkodera.

Sloj	Kanali (ulaz → izlaz)	Opis
ResBlock	1 → 32	Inicijalna ekstrakcija značajki
Conv2d ($4 \times 4, s = 2$)	32 → 64	Prostorno smanjivanje $2\times$
ResBlock	64 → 64	Dublja obrada
Conv2d ($4 \times 4, s = 2$)	64 → 128	Prostorno smanjivanje $2\times$
ResBlock	128 → 128	Dublja obrada
Conv2d ($4 \times 4, s = 2$)	128 → 128	Prostorno smanjivanje $2\times$
Conv2d ($\mu, 3 \times 3$)	128 → 16	Glava za sredinu posteriora
Conv2d ($\sigma^2, 3 \times 3$)	128 → 16	Glava za log-varijancu posteriora

Tablica 3.4. Sekvencijalna arhitektura VAE dekodera.

Sloj	Kanali (ulaz → izlaz)	Opis
Conv2d projekcija (3×3)	16 → 128	Projekcija na unutarnji prostor značajki
ResBlock	128 → 128	Obrada na razini latentne mreže
ConvTranspose2d ($4 \times 4, s = 2$)	128 → 128	Povećanje prostorne razlučivosti $2\times$
ResBlock	128 → 64	Smanjivanje broja kanala
ConvTranspose2d ($4 \times 4, s = 2$)	64 → 64	Povećanje prostorne razlučivosti $2\times$
ResBlock	64 → 32	Smanjivanje broja kanala
ConvTranspose2d ($4 \times 4, s = 2$)	32 → 32	Povećanje prostorne razlučivosti $2\times$
Conv2d izlaz (3×3)	32 → 1	Izlazna projekcija
Sigmoid	—	Aktivacija, izlaz u $[0, 1]$

Nakon primjene aktivacije sigmoid, izlaz dekodera $\hat{\mathbf{x}}$ ima oblik $(B, 1, H, W)$ s vrijednostima u $[0, 1]$, identičan obliku i rasponu ulaznog spektrograma. Radi robustnosti, izlaz se još izrezuje (*match_size*) na izvorne prostorne dimenzije ulaza ako zbog parnosti paddinga transpozicijska konvolucija unese višak jednog retka ili stupca.

3.6.2. Latentna reprezentacija i reparametrizacijski trik

VAE modelira uvjetnu distribuciju latentnog vektora kao:

$$q_{\phi}(\mathbf{z} \mid \mathbf{x}) = \mathcal{N}(\mathbf{z}; \boldsymbol{\mu}_{\phi}(\mathbf{x}), \text{diag}(\exp(\boldsymbol{\ell}_{\phi}(\mathbf{x})))),$$

gdje su $\boldsymbol{\mu}_{\phi}(\mathbf{x})$ i $\boldsymbol{\ell}_{\phi}(\mathbf{x}) = \log \sigma_{\phi}^2(\mathbf{x})$ izlazi enkoderskih glava. Budući da stohastičko uzorkovanje $\mathbf{z} \sim q_{\phi}(\mathbf{z} \mid \mathbf{x})$ blokira protok gradijenata, koristi se **reparametrizacijski trik** [12]:

$$\mathbf{z} = \boldsymbol{\mu} + \boldsymbol{\varepsilon} \odot \exp\left(\frac{1}{2} \boldsymbol{\ell}\right), \quad \boldsymbol{\varepsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}).$$

Stohastičnost je time premještena u deterministički $\boldsymbol{\varepsilon}$, pa gradienti mogu slobodno teći kroz $\boldsymbol{\mu}$ i $\boldsymbol{\ell}$ do parametara enkodera.

Latentna reprezentacija ima oblik $(B, 16, H/8, W/8)$. Za isječak trajanja 10 sekundi, uz parametre mel-spektrograma i faktor kompresije 8×, tipične prostorne dimenzije latentnog tenzora su $(B, 16, 10, 27)$, što predstavlja znatno manje dimenzionalan prostor od izvornog spektrograma dimenzije $(1, 80, 216)$.

3.6.3. Funkcija gubitka i žarenje KL termina

Ukupna funkcija gubitka VAE-a temelji se na varijacijskoj donjoj granici (*Evidence Lower Bound*, ELBO) [12]:

$$\mathcal{L}_{\text{VAE}} = \mathcal{L}_{\text{rekon}} + \beta \cdot \mathcal{L}_{\text{KL}}.$$

Rekonstrukcijska greška mjeri se L1 normom između rekonstruiranog mel-spektrograma $\hat{\mathbf{x}}$ i originalnog $\mathbf{x}$:

$$\mathcal{L}_{\text{rekon}} = \frac{1}{|\mathbf{x}|} \sum_i |\hat{x}_i - x_i|.$$

Korištenje L1 norme (MAE) umjesto L2 (MSE) potiče oštrije rekonstrukcije i manje je osjetljivo na izražene vrijednosti u mel-spektrogramu.

KL divergencija mjeri udaljenost između posteriora $q_\phi(\mathbf{z} | \mathbf{x})$ i izabranog priora $p(\mathbf{z}) = \mathcal{N}(\mathbf{0}, \mathbf{I})$:

$$\mathcal{L}_{\text{KL}} = -\frac{1}{2} \mathbb{E}[1 + \ell - \mu^2 - \exp(\ell)],$$

gdje se očekivanje uzima po svim prostornim pozicijama i kanalima latentnog tenzora. Ova forma KL divergencije ima analitičko rješenje za normalnu distribuciju i standardni normalni prior.

Težinski parametar $\beta = 10^{-3}$ (KL_WEIGHT) regulira ravnotežu između rekonstrukcije i regularizacije. Mala vrijednost β daje prednost rekonstrukcijskoj preciznosti, dok se latentnom prostoru dopušta određena sloboda od standardne normalne distribucije, što je u skladu s ciljem kvalitetne rekonstrukcije spektrograma.

Žarenje KL termina (engl. *annealing*) rješava poznati problem kolapsa posteriora pri treniranju VAE-a: enkoder uči ignorirati ulaz i vraća prior ($\mu \approx \mathbf{0}$, $\sigma \approx \mathbf{1}$), jer je to najlakši način minimiziranja KL člana. Kako bi se taj fenomen spriječio, primjenjuje se linearno KL tempiranje: u prvih $N_{\text{anneal}} = 10$ epoha težinski parametar linearno raste od

0 do β :

$$\beta(e) = \beta \cdot \min\left(1, \frac{e}{N_{\text{anneal}}}\right), \quad e = 0, 1, \dots$$

U ranoj fazi učenja model se time fokusira isključivo na rekonstrukciju i gradi korisne latentne reprezentacije, a tek potom uvodi KL regularizacija koja latentni prostor “zaokružuje” prema normalnoj distribuciji.

3.6.4. Postupak učenja

VAE se trenira na isječcima skladbi umanjenog MUSDB18 podskupa za učenje radi bržeg razvoja i validacije arhitekture. Skup se dijeli na 80% za učenje i 20% za validaciju.

Hiperparametri treniranja sažeti su u tablici 3.5.

Tablica 3.5. Hiperparametri treniranja VAE-a.

Parametar	Vrijednost	Opis
AE_EPOCHS	30	Ukupan broj epoha
BATCH_SIZE	8	Veličina skupa primjera
Optimizator	Adam	Adaptivna metoda gradijentnog spusta
Stopa učenja	10^{-4}	Fiksna stopa kroz cijelo treniranje
KL_WEIGHT (β)	10^{-3}	Konačna KL težina
KL_ANNEAL_EPOCHS	10	Broj epoha linearnog KL rasta
Omjer train/val	80%/20%	Dijeljenje isječaka
Broj skladbi	15	Podskup za brži razvoj

Pri svakoj epohi provodi se prolaz unaprijed kroz enkoder i dekoder, izračun gubitka $\mathcal{L}_{\text{VAE}}$, prolaz unatrag i korak optimizatora. Uz svaku epohu prati se validacijska greška (L1 + KL) na validacijskom podskupu bez ažuriranja parametara. Na kraju svake epohe sprema se *checkpoint* koji sadrži stanje modela, povijest gubitka te meta-parametre `latent_channels` i `mel_time_divisor` potrebne za rekonstrukciju arhitekture pri inferenciji.

3.7. Difuzijski model u latentnom prostoru

Difuzijski model u latentnom prostoru (LDM, *Latent Diffusion Model*) [20] čini drugu fazu sustava. Trenira se na latentnim reprezentacijama koje proizvodi zamrznuti VAE enkoder te uči modelirati distribuciju tih reprezentacija putem obrnutog Markovljevog

procesa. Za generiranje novih uzoraka dovoljno je Gaussovim šumom inicijalizirati latentni vektor i provesti obrnuti difuzijski proces.

3.7.1. Raspored šuma i unaprijedni proces

Unaprijedni difuzijski proces postupno dodaje Gaussov šum latentnom vektoru $\mathbf{z}_0$ kroz T diskretnih koraka, definirajući Markovljev lanac:

$$q(\mathbf{z}_t | \mathbf{z}_{t-1}) = \mathcal{N}(\mathbf{z}_t; \sqrt{1 - \beta_t} \mathbf{z}_{t-1}, \beta_t \mathbf{I}).$$

Uz oznaku $\alpha_t = 1 - \beta_t$ i $\bar{\alpha}_t = \prod_{s=1}^t \alpha_s$, marginalna distribucija u koraku t daje se u zatvorenom obliku (bez uzorkovanja svih međukoraka) [15]:

$$q(\mathbf{z}_t | \mathbf{z}_0) = \mathcal{N}(\mathbf{z}_t; \sqrt{\bar{\alpha}_t} \mathbf{z}_0, (1 - \bar{\alpha}_t) \mathbf{I}),$$

što se izravno implementira kao:

$$\mathbf{z}_t = \sqrt{\bar{\alpha}_t} \mathbf{z}_0 + \sqrt{1 - \bar{\alpha}_t} \boldsymbol{\varepsilon}, \quad \boldsymbol{\varepsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}).$$

Za raspored šuma (*noise schedule*) koristi se linearni raspored kao u originalnom DDPM radu [15]:

$$\beta_t = \text{linspace}(10^{-4}, 0,02, T), \quad T = 200.$$

Parametri rasporeda sažeti su u tablici 3.6.

Tablica 3.6. Parametri rasporeda šuma.

Parametar	Vrijednost	Opis
T	200	Ukupan broj difuzijskih koraka
β_1	10^{-4}	Početna vrijednost rasporeda šuma
β_T	0,02	Završna vrijednost rasporeda šuma
Tip rasporeda	Linearni	Jednoliko raspoređen između β_1 i β_T

Za $t = T$ vrijedi $\bar{\alpha}_T \approx 0$, pa je $\mathbf{z}_T \approx \boldsymbol{\varepsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$. Latentni vektor postaje Gaussov šum. Simetričan cilj obrnutog procesa jest poći od tog šuma i postupno rekonstruirati $\mathbf{z}_0$.

3.7.2. Arhitektura U-Net denoisera

Obrnuti difuzijski korak uči parametrizirana neuronska mreža, U-Net arhitektura [43] prilagođena za uvjetovanje na vremenski korak t . Mreža prima zašumljeni latentni tenzor $\mathbf{z}_t$ oblika $(B, 16, H', W')$ i diskretni vremenski korak t te predviđa šum ϵ (ϵ -parametrizacija).

Osnovna gradivna jedinica U-Net denoisera jest UNetBlock. Za razliku od VAE-ovog ResBlock-a, ovaj blok prihvaća i vremenske ugradnje (engl. *time embedding*) koji modulira aktivacije:

$$\begin{aligned}\mathbf{h} &= \sigma(\text{GN}(\text{Conv}_{3\times 3}(\mathbf{x}))), \\ \mathbf{h} &+= W_t \cdot \mathbf{t}_{\text{emb}} \quad (\text{prostorni broadcast}), \\ \mathbf{h}' &= \text{GN}(\text{Conv}_{3\times 3}(\mathbf{h})), \\ \text{izlaz} &= \sigma(\mathbf{h}') + \text{skip}(\mathbf{x}),\end{aligned}$$

gdje je $W_t \cdot \mathbf{t}_{\text{emb}}$ linearna projekcija vremenske ugradnje na broj kanala bloka, prostorom emitirana (engl. *broadcast*) po dimenzijama H' i W' . Ključno je da se injekcija vremenskog ugradka odvija nakon prve GroupNorm i SiLU aktivacije, što prati DDPM/LDM konvenciju i sprječava normalizacijski sloj od poništavanja vremenskog uvjetovanja [15].

Mreža je organizirana kao klasični enkoder-dekoder sa skip vezama između odgovarajućih razina:

Tablica 3.7. Arhitektura U-Net denoisera.

Komponenta	Kanali (ulaz → izlaz)	Opis
Ulazna projekcija (in_conv)	16 → 64	Conv2d 3×3 , pad=1
Enkoder		
down1: UNetBlock	64 → 64	Razina 1 (<i>skip: d1</i>)
pool1: Conv2d ($s = 2$)	64 → 64	Poduzorkovanje $2\times$
down2: UNetBlock	64 → 128	Razina 2 (<i>skip: d2</i>)
pool2: Conv2d ($s = 2$)	128 → 128	Poduzorkovanje $2\times$
down3: UNetBlock	128 → 256	Razina 3 (<i>skip: d3</i>)
pool3: Conv2d ($s = 2$)	256 → 256	Poduzorkovanje $2\times$
Usko grlo		
mid: UNetBlock	256 → 256	Bottleneck
Dekoder		
up3: ConvTranspose2d ($s = 2$)	256 → 256	Uzorkovanje gore $2\times$
cat($\cdot, \mathbf{d}_3$) dec3: UNetBlock	512 → 256	Skip s razinom 3
up2: ConvTranspose2d ($s = 2$)	256 → 128	Uzorkovanje gore $2\times$
cat($\cdot, \mathbf{d}_2$) dec2: UNetBlock	256 → 128	Skip s razinom 2
up1: ConvTranspose2d ($s = 2$)	128 → 64	Uzorkovanje gore $2\times$
cat($\cdot, \mathbf{d}_1$) dec1: UNetBlock	128 → 64	Skip s razinom 1
Izlazna projekcija (out)	64 → 16	Conv2d 3×3 , pad=1,

Skip veze međusobno spajaju enkoder i dekodeer na svakoj od triju razina, čime se detaljna prostorna informacija prenosi izravno na odgovarajuću razinu dekodeera i obogaćuje obrnuti proces visokofrekvencijskim strukturama latentnog prostora. U dekodeeru se skip i uzorkovani tenzor konkatenuiraju po kanalnoj dimenziji, zbog čega dolazi do udvostručavanja broja ulaznih kanala.

3.7.3. Vremenska ugradnja

Kako bi denoiser znao na koji vremenski korak t treba uvjetovati svoju predikciju, vremenski korak se kodira u gust vektorski prikaz (engl. *time embedding*). Postupak se sastoji od dva koraka:

Prvi korak je sinusoidalna vremenska ugradnja (engl. *Sinusoidal Time Embedding*). Diskretni vremenski korak $t \in \{0, 1, \dots, T - 1\}$ pretvara se u vektor dimenzije 128 po uzoru na pozicijske ugradnje u transformerima [44]:

$$f_i = \frac{1}{10000^{i/(d/2)}}, \quad i = 0, 1, \dots, d/2 - 1,$$

$$\mathbf{e}(t) = [\sin(t \cdot f_0), \sin(t \cdot f_1), \dots, \sin(t \cdot f_{d/2-1}), \cos(t \cdot f_0), \cos(t \cdot f_1), \dots, \cos(t \cdot f_{d/2-1})]^\top \in \mathbb{R}^d,$$

gdje je $d = 128$ (time_dim). Sinusni i kosinusni dijelovi nisu isprepleteni, već su grupirani: prvih $d/2$ elemenata čine sinusne, a posljednjih $d/2$ kosinusne komponente. Ovaj sinusoidalni ugradak osigurava glatku interpolabilnost između vremenskih koraka i bi-jektivno kodiranje svakog koraka.

Drugi korak je preslikavanje sinusoidalne ugradnje dvoslojnom neuronskom mrežom s aktivacijom:

$$\mathbf{t}_{\text{emb}} = W_2 \cdot \sigma(W_1 \cdot \mathbf{e}(t) + \mathbf{b}_1) + \mathbf{b}_2,$$

gdje su $W_1, W_2 \in \mathbb{R}^{128 \times 128}$. Time se uvodi nelinearnost i omogućava U-Net mreži da nauči korisne transformacije vremenskog signala prilagođene specifičnim potrebama zadatka uklanjanja šuma.

Vremenski ugradak $\mathbf{t}_{\text{emb}} \in \mathbb{R}^{128}$ zajednički se računa za cijeli skup primjera i proslijeđuje u svaki UNetBlock u cijeloj mreži, gdje se projicira na broj kanala pojedinog bloka linearnom transformacijom $W_t \in \mathbb{R}^{C_{\text{out}} \times 128}$.

3.7.4. Funkcija gubitka i postupak učenja

Difuzijski model trenira se u ε -parametrizaciji [15]: umjesto predviđanja dekonstruiranog uzorka $\mathbf{z}_0$, mreža predviđa šum ε koji je dodan u unaprijednom procesu. Teorijski je pokazano [15] da ova parametrizacija daje bolje rezultate od izravnog predviđanja uzorka. Funkcija gubitka je:

$$\mathcal{L}_{\text{LDM}} = \mathbb{E}_{t, \mathbf{z}_0, \varepsilon} \left[\left\| \varepsilon - \varepsilon_{\theta}(\mathbf{z}_t, t) \right\|_2^2 \right],$$

gdje je ε_{θ} U-Net denoiser s parametrima θ , a t uniformno uzorkovan iz $\{0, 1, \dots, T - 1\}$.

Difuzijski model prima posteriornu sredinu $\boldsymbol{\mu}$ iz zamrznutog VAE enkodera, a ne stohastički uzorak $\mathbf{z} = \boldsymbol{\mu} + \boldsymbol{\varepsilon}' \odot \boldsymbol{\sigma}$. Ovaj pristup slijedi originalni LDM rad (Rombach et al., 2022) [20]. Korištenjem deterministične posteriorne sredine kao cilja modela izbjegava se prilagodba jednoj konkretnoj bučnoj realizaciji, čime se stabilizira treniranje i smanjuje varijanca gradijenata.

Prije nego što se $\boldsymbol{\mu}$ koristi kao $\mathbf{z}_0$ u unaprijednom procesu, normalizira se po kanalima

na temelju statistika cjelokupnog skupa za učenje:

$$\mathbf{z}_{\text{norm}} = \frac{\boldsymbol{\mu} - \boldsymbol{\mu}_{\text{mean}}}{\boldsymbol{\mu}_{\text{std}}},$$

gdje su $\boldsymbol{\mu}_{\text{mean}}$ i $\boldsymbol{\mu}_{\text{std}}$ empirijski izračunati kanalni prosjek i standardna devijacija svih $\boldsymbol{\mu}$ tenzora u skupu za učenje. Ovim korakom latentni vektori centriraju se oko nule i normaliziraju, što je pretpostavka difuzijskog modela koji počiva na standardnoj normalnoj distribuciji u koraku T .

Hiperparametri treniranja difuzijskog modela sažeti su u tablici 3.8.

Tablica 3.8. Hiperparametri treniranja difuzijskog modela.

Parametar	Vrijednost	Opis
DIFF_EPOCHS	600	Ukupan broj epoha treniranja
BATCH_SIZE	8	Veličina skupa primjera
Optimizator	Adam	Adaptivna metoda gradijentnog spusta
Stopa učenja	10^{-4}	Fiksna stopa kroz cijelo treniranje
T (difuzijski koraci)	200	Broj koraka unaprijednog procesa
Broj skladbi	150	Sve skladbe iz MUSDB18

Pri svakoj iteraciji treniranja:

1. za svaki primjer u skupu primjera uniformno se odabire vremenski korak $t \sim \mathcal{U}(0, T - 1)$
2. primjenjuje se unaprijedni difuzijski korak u zatvorenom obliku za dobivanje $\mathbf{z}_t$ i šuma $\boldsymbol{\varepsilon}$
3. U-Net predviđa šum $\boldsymbol{\varepsilon}_{\theta}(\mathbf{z}_t, t)$
4. računa se MSE gubitak i provodi korak optimizatora.

3.8. Inferencija i generiranje zvuka

Generiranje novih glazbenih isječaka provodi se u tri koraka:

1. uzorkovanje latentnog vektora $\mathbf{z}_0$ obrnutim difuzijskim procesom,
2. dekodiranje $\mathbf{z}_0$ zamrznutim VAE dekomerom u mel-spektrogram te

3. inverzna pretvorba mel-spektrograma u zvučni valni oblik.

Navedeni niz operacija provodi se bez uvjetnih ulaza, generirani isječci su u potpunosti stohastički i vođeni naučenom distribucijom.

3.8.1. DDPM obrnuti proces uzorkovanja

Obrnuti postupak [15] iterativno uklanja slučajni Gaussov šum korak po korak od $t = T - 1$ do $t = 0$, uzorkujući iz naučenog obrnutog kernela:

$$p_{\theta}(\mathbf{z}_{t-1} | \mathbf{z}_t) = \mathcal{N}(\mathbf{z}_{t-1}; \boldsymbol{\mu}_{\theta}(\mathbf{z}_t, t), \beta_t \mathbf{I}).$$

Uz ε -parametrizaciju, rekursivni korak glasi:

$$\mathbf{z}_{t-1} = \frac{1}{\sqrt{\alpha_t}} \left(\mathbf{z}_t - \frac{1 - \alpha_t}{\sqrt{1 - \bar{\alpha}_t}} \boldsymbol{\varepsilon}_{\theta}(\mathbf{z}_t, t) \right) + \sqrt{\beta_t} \boldsymbol{\varepsilon}', \quad \boldsymbol{\varepsilon}' \sim \mathcal{N}(\mathbf{0}, \mathbf{I}),$$

pri čemu se stohastički šum $\sqrt{\beta_t} \boldsymbol{\varepsilon}'$ dodaje samo za $t > 0$ (za $t = 0$ ne dodaje se šum, jer je $\mathbf{z}_0$ traženi generirani uzorak).

Cjelokupni postupak uzorkovanja opisuje se pseudokodom:

1. Inicijalizacija: $\mathbf{z}_T \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$, oblik $(1, 16, H', W')$.
2. Za $t = T - 1, T - 2, \dots, 1$:
 - (a) Predvidi šum: $\boldsymbol{\varepsilon}_{\text{pred}} = \boldsymbol{\varepsilon}_{\theta}(\mathbf{z}_t, t)$.
 - (b) Izračunaj: $\mathbf{z}_{t-1} = \frac{1}{\sqrt{\alpha_t}} \left(\mathbf{z}_t - \frac{1 - \alpha_t}{\sqrt{1 - \bar{\alpha}_t}} \boldsymbol{\varepsilon}_{\text{pred}} \right) + \sqrt{\beta_t} \boldsymbol{\varepsilon}', \quad \boldsymbol{\varepsilon}' \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$.
3. Za $t = 0$: isti korak bez stohastičnog člana ($\boldsymbol{\varepsilon}' = \mathbf{0}$).
4. Denormalizacija: $\mathbf{z}_0 = \mathbf{z}_0 \cdot \boldsymbol{\sigma}_{\text{lat}} + \boldsymbol{\mu}_{\text{lat}}$, koristeći pohranjene kanalne statistike.

Postupak zahtijeva $T = 200$ prolaza kroz U-Net mrežu, što je mali broj difuzijskih koraka u usporedbi s novijim modelima koji koriste i više od 1 000 koraka [15].

3.8.2. Inverzna pretvorba spektrograma u zvuk (Griffin-Lim)

Nakon obrnutog difuzijskog procesa dobiveni $\mathbf{z}_0$ prolazi kroz zamrznuti VAE deko­der koji rekonstruira normalizirani mel-spektrogram $\hat{\mathbf{m}} \in [0, 1]^{1 \times 80 \times W'}$. Da bi se iz ovog spek­trograma dobio slušljiv zvučni valni oblik, potrebno je provesti inverznu mel-spektrogramsku transformaciju.

Budući da mel-spektrogram kodira isključivo amplitudne informacije, a ne fazne, izravna inverzna STFT transformacija nije primjenjiva bez fazne informacije. U ovom sustavu koristi se Griffin-Lim algoritam [7], iterativna metoda za procjenu faze koja minimizira nekonzistentnost STFT-a, implementirana u knjižnici `librosa` kao `librosa.feature.inverse.mel_to_audio`.

Niz koraka pretvorbe je sljedeći:

1. Denormalizacija mel-spektrograma iz $[0, 1]$ u dB skalu:

$$S_{\text{dB}} = \hat{\mathbf{m}} \cdot 80 - 80 \quad [\text{dB}].$$

2. Pretvorba u linearnu snagu:

$$S_{\text{power}} = 10^{S_{\text{dB}}/10} = \text{librosa.db_to_power}(S_{\text{dB}}).$$

3. Griffin-Lim inverzija s parametrima konzistentnima s koracima analize:

$$\hat{x} = \text{librosa.feature.inverse.mel_to_audio}(S_{\text{power}}, sr = 5512, n_fft = 1024, hop_length = 256).$$

Funkcija interno mapira linearnu mel-snagu na linearni STFT spektrogram (pseudoinverzija mel-filterbanke), potom iterativno procjenjuje fazu Griffin-Lim postupkom i primjenjuje ISTFT za dobivanje valnog oblika.

4. Ispis u WAV datoteku: Dobiveni jednodimenzionalni niz uzoraka pri $f_s = 5\,512$ Hz sprema se kao WAV datoteka pomoću knjižnice `soundfile`.

Treba napomenuti ograničenja Griffin-Lim pristupa: algoritam konvergira prema amplitudno konzistentnom valnom obliku, ali rekonstruirana faza nije nužno percep-

tivno optimalna, što može rezultirati metalčnim artefaktima koji su tipični za ovaj algoritam. Alternativni pristup jest korištenje neuronskog vokodera (npr. HiFi-GAN [8]), može dati perceptivno bolju kvalitetu zvuka, ali zahtijeva zasebno treniranje i znatno veći računalni trošak pri inferenciji.

Kompletni inferencijski pipeline od ulaznog Gaussovog šuma do izlaznog WAV zapisa sažet je u tablici 3.9.


Tablica 3.9. Pregled koraka inferencijskog pipeline-a.

Korak	Operacija	Ulaz	Izlaz
1	Inicijalizacija šumom	—	$(1, 16, H', W') \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$
2	DDPM obrnuti proces ($T=200$ koraka)	$\mathbf{z}_T$	$\mathbf{z}_0^{\text{norm}}$
3	Denormalizacija latentnog vektora	$\mathbf{z}_0^{\text{norm}}$	$\mathbf{z}_0 \in \mathbb{R}^{16 \times H' \times W'}$
4	VAE dekodiranje	$\mathbf{z}_0$	$\hat{\mathbf{m}} \in [0, 1]^{1 \times 80 \times W'}$
5	Denormalizacija mel-spektrograma	$\hat{\mathbf{m}}$	$S_{\text{dB}} \in [-80, 0] \text{ dB}$
6	dB $\rightarrow$ snaga	S_{dB}	S_{power}
7	Griffin-Lim inverzija	S_{power}	$\hat{x}$, WAV ($f_s = 5\,512 \text{ Hz}$)

4. Opis postupka vrednovanja i rezultati

Vrednovanje predloženog sustava provedeno je u sedam eksperimentalnih cjelina koje se odnose na VAE i difuzijski model zasebno, kao i na kvalitetu cjelokupnog generativnog procesa. Rezultati obuhvaćaju kvantitativne metrike, vizualnu analizu spektrograma i subjektivnu procjenu slušanjem.

4.1. Krivulje učenja varijacijskog autoenkodera



Slika 4.1. Krivulje učenja varijacijskog autoenkodera

Krivulje rekonstrukcijskog L1 gubitka za skupove za učenje i validaciju pokazuju stabilno i monotono smanjenje tijekom epoha, uz početno opadanje i postupno usporavanje prema kraju treniranja. U završnim epohama razlika između gubitka na skupu za učenje i na validacijskom skupu iznosi 0,0006, što upućuje na dobru generalizaciju modela i odsutnost izraženog pretreniranja.

Donji dio slike prikazuje ponašanje KL divergencije zajedno s rasporedom postupnog uvođenja KL člana u funkciju gubitka (engl. *KL annealing*) u prvih deset epoha treniranja. Nakon početne faze oscilacija KL divergencija se stabilizira, a potom blago raste kako se povećava težina KL regularizacije, što je očekivano ponašanje za VAE s postepenim uvođenjem regularizacijskog člana [12]. Takvo ponašanje upućuje na to da model uspješno postiže kompromis između dobre rekonstrukcije i dovoljno strukturiranog latentnog prostora.

Stabilna konvergencija i mala razlika između metrika na skupu za učenje i na validacijskom skupu preduvjet su da latentni prostori koje uči VAE budu dovoljno glatki i regularni za učinkovito učenje latentnog difuzijskog modela.

Tablica 4.1. sažima ključne numeričke pokazatelje konvergencije.


Tablica 4.1. Sažetak konvergencije VAE-a

Pokazatelj	Vrijednost
Ukupan broj epoha	30
Konačni L1 gubitak (učenje)	0,0373
Konačni L1 gubitak (validacija)	0,0379
Maksimalni razmak učenje/validacija	0,0348
Završni razmak učenje/validacija	0,0006
KL divergencija nakon annealing faze (min)	1,3435
KL divergencija nakon annealing faze (std)	0,1139


Vrijednost KL divergencije ostaje znatno iznad nule kroz cijelo treniranje, što potvrđuje da nije došlo do kolapsa posteriora.

4.2. Kvaliteta rekonstrukcije varijacijskog autoenkodera

VAE Reconstruction Quality — Test Samples



Slika 4.2. Rekonstrukcije spektrograma



Slika 4.3. Histogram L1 pogreške rekonstrukcije

Na testnom skupu od 1 223 isječaka VAE postiže prosječnu L1 rekonstrukcijsku pogrešku od $0,0383 \pm 0,0066$, dok je medijan 0,0374, što upućuje na usku distribuciju pogrešaka oko niske srednje vrijednosti. Histogram L1 pogreške pokazuje asimetričnu, ali jednomodalnu distribuciju bez izraženih repova, što znači da se većina isječaka može dobro rekonstruirati, a loše rekonstrukcije su rijetke.

Prosječna vrijednost log-spektralne udaljenosti (engl. *log-spectral distance*, LSD) iznosi $0,4049 \pm 0,0653$, a razlika spektralnog centroida $63,9 \pm 48,4$ Hz, što sugerira da se globalna raspodjela energije po frekvencijama većinski očuva kroz postupak kodiranja i dekodiranja. Pregled reprezentativnih spektrograma originalnih i rekonstruiranih isječaka potvrđuje da VAE vjerno reproducira glavne harmonijske komponente, ritmičku strukturu i grube teksturalne obrasce, dok se najveća odstupanja javljaju u visokofrekvencijskim detaljima i tranzijentima. Takav profil pogreške očekivan je za model ograničenog kapaciteta koji djeluje u latentnom prostoru niže dimenzionalnosti i pokazuje da je postignut razuman kompromis između stupnja kompresije i očuvanja perceptualno relevantnih značajki signala.

Tablica 4.2. prikazuje sve tri metrike rekonstrukcije.

Tablica 4.2. Metrike rekonstrukcije VAE-a na testnom skupu ($N = 1\,223$ isječaka)

Metrika	Srednja vrijednost $\pm$ std	Medijan
L1 pogreška	$0,0383 \pm 0,0066$	0,0374
LSD	$0,4049 \pm 0,0653$	
Razlika spektralnog centroida (Hz)	$63,9 \pm 48,4$	

4.3. Analiza latentnog prostora varijacijskog autoenkodera


Za određivanje aktivnosti latentnih kanala koristi se kriterij $\text{Var}(\mu) > 0,1$, gdje μ označava posteriornu sredinu pojedinog kanala agregiranu po cijelom skupu za učenje. Opravdanost praga od 0,1 proizlazi iz odabira standardne normalne distribucije $\mathcal{N}(0, 1)$ kao priora čija mjera skale varijance iznosi 1. Kanal s varijancom $\text{Var}(\mu) > 0,1$ ima standardnu devijaciju posteriornih sredina veću od $\sqrt{0,1} \approx 0,32$, što znači da se njegova vrijednost μ mijenja po skupu podataka s netrivialnim odklonom od nule. Kanali s varijancom ispod 0,1 ostaju gotovo konstantni bez obzira na ulazni isječak i ponašaju se kao

dimenzija koja ne prenosi informaciju o ulazu.

Analiza varijance po latentnim kanalima pokazuje da je 10 od 16 dimenzija aktivno prema navedenom kriteriju, dok preostalih 6 dimenzija ostaje slabo pobuđeno. Tablica 4.3. prikazuje vrijednosti varijance po kanalima. To znači da model učinkovito koristi većinu raspoloživih latentnih jedinica, ali istodobno zadržava određeni stupanj redundancije.

Tablica 4.3. Varijanca posteriornih sredina po latentnim kanalima. Kanal je aktivan ako $\text{Var}(\mu) > 0,1$


Kanal	Varijanca	Aktivan	Kanal	Varijanca	Aktivan
0	0,2645	Da	8	0,0327	
1	0,1118	Da	9	0,0203	
2	0,2387	Da	10	0,3957	Da
3	0,0286		11	0,3259	Da
4	0,5618	Da	12	0,1650	Da
5	0,2887	Da	13	0,0454	
6	0,1990	Da	14	0,0236	
7	0,0557		15	0,1056	Da
Aktivnih kanala: 10 / 16					



Slika 4.4. Analiza posteriorne distribucije po latentnim kanalima

Distribucije posteriornih sredina po kanalima približno prate univarijatnu normalnu raspodjelu, uz male pomake sredine i standardne devijacije oko zadane priorne $\mathcal{N}(0, 1)$. Time se potvrđuje da KL regularizacija uspješno oblikuje latentni prostor tako da ostane dobro usklađen s Gausovim priorom, što je poželjno svojstvo za uzorkovanje i treniranje difuzijskog modela u latentnoj domeni [20].

4.4. Konvergencija učenja difuzijskog modela



Slika 4.5. Krivulja gubitka difuzijskog modela

Krivulja MSE gubitka tijekom 600 epoha treniranja pokazuje glatko i monotono smanjenje od početne vrijednosti 1,02 do završne vrijednosti 0,11, pri čemu se minimalni gubitak (0,0888) postiže oko 479. epohe. U ranim fazama treniranja vidljivo je brzo opadanje gubitka, nakon čega slijedi faza sporijeg, ali i dalje stabilnog poboljšanja, što upućuje na to da model najprije uči grube obrasce šuma u latentnom prostoru, a zatim finije pojedinosti distribucije.


Eksponencijalno zaglađena krivulja gubitka dodatno naglašava da, nakon inicijalne tranzijentne faze, nema znakova divergencije niti oscilacija velike amplitude, što sugerira numeričku stabilnost optimizacije i prikladan odabir hiperparametara treniranja: stope učenja, veličine skupa primjera i rasporeda šuma.

Tablica 4.4. sažima ključne vrijednosti krivulje konvergencije.

Tablica 4.4. Sažetak konvergencije difuzijskog modela

Pokazatelj	Vrijednost
Ukupan broj epoha	600
Početni MSE gubitak	1,0181
Završni MSE gubitak	0,1129
Minimalni MSE gubitak	0,0888 (epoha 479)

4.5. Spektralni deskriptori generiranih uzoraka



Slika 4.6. Spektralni deskriptori generiranih uzoraka

Usporedba osnovnih spektralnih deskriptora između generiranih uzoraka i referentnih isječaka iz skupa MUSDB18 prikazana je u tablici 4.5.

Tablica 4.5. Spektralni deskriptori generiranih uzoraka i referentnog skupa MUSDB18 (srednja vrijednost $\pm$ std)

Deskriptor	Generirani	Referentni (MUSDB18)
Spektralni centroid (Hz)	$2705,6 \pm 236,7$	$1902,4 \pm 236,7$
Spektralni fluks	$0,580 \pm 0,060$	$17,112 \pm 4,149$
Spektralna ravnoća	$0,237 \pm 0,066$	$0,033 \pm 0,026$

Generirani uzorci imaju viši prosječni spektralni centroid (2 706 Hz) od referentnih isječaka (1 902 Hz), što znači da je energija spektra pomaknuta prema višim frekvencijama i da generirani zvukovi zvuče svjetlije i oštrije od izvornog materijala. Spektralna ravnoća generiranih uzoraka višestruko je veća (0,237 nasuprot 0,033), što je obilježje šumovitijeg spektra i upućuje na to da model proizvodi signale s manje izraženim tonalnim vrhovima i ravnomjernije raspoređenom energijom po frekvencijama.

Spektralni fluks generiranih uzoraka manji je od fluksa referentnih snimki (0,58 nasuprot 17,11). To sugerira da model uspješno sintetizira stacionarnije, teksturalne dijelove spektra, ali ima poteškoće s preciznim modeliranjem dinamičkih promjena poput artikulacije, prijelaza između akorda i napada instrumenata, pa generirana glazba može zvučati statičnije i manje artikulirano od stvarnih snimki. S druge strane, prosječni MFCC koeficijenti (engl. *Mel-frequency cepstral coefficients*) generiranih uzoraka približno prate trend referentnih MFCC-ova, što znači da globalni oblik spektra i grubi timbralni karakter ostaju relativno slični, iako je model sklon preuveličavanju visokofrekvencijskog sadržaja.

4.6. Kvaliteta generiranih uzoraka

Kvaliteta generiranih uzoraka kvantitativno je procijenjena pomoću mjere Fréchet Audio Distance [32] u VGGish značajkama [33]. Korišteno je po 200 generiranih i referentnih isječaka iz skupa MUSDB18, s ukupno 2 000 ulomaka ugradnje po skupu. Generirani uzorci izvorno su uzorkovni frekvencijom 5 512 Hz te su prije ugradnje ponovno uzorkovani na 16 000 Hz kako bi odgovarali ulaznom formatu VGGish modela, pri čemu dimenzionalnost ugradnje iznosi 128.

Tablica 4.6. prikazuje dobivene vrijednosti FAD-a.


Tablica 4.6. Rezultati evaluacije Fréchet Audio Distance (FAD)

Evaluacija	FAD
Referentni skup (self-FAD, MUSDB → MUSDB)	1,9123
Model (generirani → MUSDB)	15,7171
Omjer model / self-FAD	8,22×

Vrijednost referentne donje granice FAD-a je 1,91 (MUSDB → MUSDB). FAD između generiranih uzoraka i referentnog skupa iznosi 15,72, što je oko 8 puta više od referentne vrijednosti.

Povišena FAD vrijednost pokazuje da distribucija ugradnji generiranih uzoraka još uvijek značajno odstupa od distribucije stvarnih skladba, što znači da model ne uspijeva u potpunosti zahvatiti statistička obilježja glazbe na razini viših, semantičkih značajki koje detektira VGGish. Činjenica da je FAD vrijednost konzistentna kroz više pokretanja evaluacije upućuje na to da se generirani uzorci nalaze u istom prostoru značajki kao i referentni podaci, ali da je za smanjenje jaza između postignutog FAD-a i donje granice zadane self-FAD-om potrebno unaprijediti treniranje, primjerice dužim učenjem, jačom ili drukčijom regularizacijom, poboljšanom arhitekturom VAE-a ili zamjenom Griffin–Lim algoritma neuronskim vokoderom.

4.7. Subjektivna analiza generiranih uzoraka



Slika 4.7. Primjeri generiranih spektrograma

Subjektivnim slušanjem uzoraka generiranih latentnim difuzijskim modelom može se zaključiti da sustav uspješno generira prepoznatljive glazbene strukture: na spektrogramima su vidljive melodijske linije i akordske progresije, a u zvuku se jasno razabiru tonalni odnosi i osnovni harmonski okvir. Ipak, model ima značajne poteškoće s vjerodostojnim oblikovanjem ritma i finih vremenskih detalja, pa su perkusivni elementi i dinamične promjene slabo izražene, što rezultira dojmom zamagljene ritmičke strukture.

U prvom planu dominira kontinuiran, vokaloidan spektar, dok se akordi i ostali pratеći elementi pojavljuju u pozadini kao razmazane, jekovite teksture. Navedeni dojam konzistentan je s objektivnim nalazima povišenog spektralnog centroida i spektralne ravnoće te smanjenog spektralnog fluksa, koji upućuju na svjetliji, šumniji, ali i vremenski statičniji zvuk od referentnih snimki.

U rekonstruiranim signalima prisutni su artefakti povezani s Griffin–Lim algoritmom za rekonstrukciju faze, koji se manifestiraju kao metalizirani šum i blaga fluktuacija amplitude, dodatno naglašavajući dojam jeke i zamagljenja.

5. Zaključak

Ovaj rad predstavlja i evaluira sustav za bezuvjetno generiranje glazbe koji kombinira varijacijski autoenkoder i latentni difuzijski model temeljen na U-Net arhitekturi. Sustav je uvježban isključivo na skupu podataka MUSDB18 bez uvjetovanja tekstem, oznakama ili metapodacima, s ciljem da pokaže izvedivost latentnog difuzijskog pristupa generiranju glazbe u akademskom računalnom okruženju.

Središnja pretpostavka rada bila je da provođenje generativnog difuzijskog procesa u kompaktnom latentnom prostoru zamrznutog varijacijskog autoenkodera, umjesto izravno u prostoru izvornog valnog oblika ili punorezolucijskog spektrograma, smanjuje dimenzionalnost problema i čini ga rješivim s ograničenim računalnim resursima.

Varijacijski autoenkoder uspješno je naučio kompaktnu i dobro strukturiranu latentnu reprezentaciju log-mel spektrograma. Na testnom skupu od 1 223 isječaka postignuta je prosječna L1 rekonstrukcijska pogreška od $0,0383 \pm 0,0066$, uz prosječnu log-spektralnu udaljenost od $0,4049 \pm 0,0653$ i razliku spektralnog centroida od $63,9 \pm 48,4$ Hz. Analiza latentnog prostora pokazuje da je 10 od 16 latentnih kanala aktivno te da distribucije posteriornih sredina po kanalima dobro prate zadanu priornu raspodjelu $\mathcal{N}(0, 1)$, bez znakova kolapsa posteriora. Time je potvrđen prvi istraživački cilj: VAE pruža gladak, regulariziran i stabilan latentni prostor pogodan za naknadno učenje difuzijskog modela.

Latentni difuzijski model konvergirao je stabilno kroz 600 epoha treniranja, smanjujući MSE gubitak s početne vrijednosti 1,02 na završnih 0,11, s postignutim minimumom od 0,0888 oko 479. epohe. Glatka krivulja konvergencije bez znakova nestabilnosti potvrđuje prikladan odabir hiperparametara i arhitekture.

Međutim, kvantitativna evaluacija kvalitete generiranih uzoraka otkriva znatnu razliku u odnosu na referentnu distribuciju. Mjera Fréchet Audio Distance (FAD) u VGGish

ugradnjama iznosi 15,72 za generirane uzorke, što je oko 8 puta više od self-FAD-a referentnog skupa (1,91). Analiza spektralnih deskriptora pokazuje sustavna odstupanja: generirani uzorci imaju viši spektralni centroid (2 706 Hz nasuprot 1 902 Hz referentnih), veću spektralnu ravnost (0,237 nasuprot 0,033) i manji spektralni fluks (0,58 nasuprot 17,11). Subjektivnom analizom potvrđeno je da generirani zvukovi sadrže prepoznatljive harmonijske i melodijske elemente, ali pate od zamućene ritmičke strukture, povišene šumovitosti i artefakata karakterističnih za Griffin–Lim algoritam za rekonstrukciju faze.

Opisana odstupanja upućuju na nekoliko ograničenja predloženog sustava. Snižem uzorkovne frekvencije na 5 512 Hz i korištenjem samo 80 melskih pojaseva postigla se računalna izvedivost, no po cijenu gubitka visokofrekvencijskih detalja i perceptivne vjernosti zvuka. Griffin–Lim algoritam za inverznu pretvorbu spektrograma u zvuk uvodi fazne artefakte koji smanjuju kvalitetu rekonstruiranog audio signala. Osim toga, mali skup podataka od 150 skladbi i ograničeni kapacitet modela nisu dostatni za zahvaćanje pune raznolikosti glazbenih distribucija kakvu detektira VGGish.

Budući rad mogao bi se usmjeriti na nekoliko smjerova poboljšanja. Zamjena Griffin–Lim algoritma neuronskim vokoderom, poput HiFi-GAN-a, uklonila bi najistaknutije perceptivne artefakte. Povećanje kapaciteta U-Net denoisera, produženo treniranje i treniranje na većem skupu podataka očekivano bi poboljšali FAD i distribucijsku sličnost generiranih uzoraka. Uvođenje uvjetovanja, primjerice uvjetovanja bez klasifikatora, otvorilo bi mogućnost kontroliranog generiranja prema žanru, raspoloženju ili instrumentaciji.

Unatoč navedenim ograničenjima, ovaj rad pokazuje da je kombinacija varijacijskog autoenkodera i latentnog difuzijskog modela konceptualno izvediv pristup bezuvjetnom generiranju glazbe koji se može uvježbati s akademski dostupnim računalnim resursima. Sustav uspješno uči smislen latentni prostor glazbenih spektrograma i generira uzorke s prepoznatljivim glazbenim svojstvima, čime se potvrđuje osnovanost latentnog difuzijskog pristupa kao platforme za daljnji razvoj prema perceptivno uvjerljivom generiranju glazbe.

Literatura

- [1] A. van den Oord, S. Dieleman, H. Zen, K. Simonyan, O. Vinyals, A. Graves, N. Kalchbrenner, A. Senior, i K. Kavukcuoglu, “Wavenet: A generative model for raw audio”, *arXiv preprint arXiv:1609.03499*, 2016. <https://doi.org/10.48550/arXiv.1609.03499>
- [2] P. Dhariwal, H. Jun, C. Payne, J. W. Kim, A. Radford, i I. Sutskever, “Jukebox: A generative model for music”, *arXiv preprint arXiv:2005.00341*, 2020. <https://doi.org/10.48550/arXiv.2005.00341>
- [3] Wikipedija, slobodna enciklopedija. (2026) Heisenbergovo načelo neodređenosti. Pristupljeno: 26. lipnja 2026. [Mrežno]. Adresa: https://hr.wikipedia.org/wiki/Heisenbergovo_na%C4%8Delo_neodre%C4%91enosti
- [4] H. Purwins, B. Li, T. Virtanen, J. Schlüter, S.-y. Chang, i T. Sainath, “Deep learning for audio signal processing”, *IEEE Journal of Selected Topics in Signal Processing*, sv. 13, br. 2, str. 206–219, 2019. <https://doi.org/10.1109/JSTSP.2019.2908700>
- [5] A. Défossez, J. Copet, G. Synnaeve, i Y. Adi, “High fidelity neural audio compression”, *arXiv preprint arXiv:2210.13438*, 2022. <https://doi.org/10.48550/arXiv.2210.13438>
- [6] R. Kumar, P. Seetharaman, A. Luebs, I. Kumar, i K. Kumar, “High-fidelity audio compression with improved rvqgan”, *arXiv preprint arXiv:2306.06546*, 2023. <https://doi.org/10.48550/arXiv.2306.06546>
- [7] D. Griffin i J. Lim, “Signal estimation from modified short-time fourier transform”, *IEEE Transactions on Acoustics, Speech, and Signal Processing*, sv. 32, br. 2, str. 236–243, 1984. <https://doi.org/10.1109/TASSP.1984.1164317>

- [8] J. Kong, J. Kim, i J. Bae, “Hifi-gan: Generative adversarial networks for efficient and high fidelity speech synthesis”, *arXiv preprint arXiv:2010.05646*, 2020. <https://doi.org/10.48550/arXiv.2010.05646>
- [9] S. Mehri, K. Kumar, I. Gulrajani, R. Kumar, S. Jain, J. Sotelo, A. Courville, i Y. Bengio, “SAMPLERNN: An unconditional end-to-end neural audio generation model”, *arXiv preprint arXiv:1612.07837*, 2016. <https://doi.org/10.48550/arXiv.1612.07837>
- [10] K. Kumar, R. Kumar, T. de Boissiere, L. Gestein, W. Z. Teoh, J. Sotelo, A. de Brébisson, Y. Bengio, i A. Courville, “Melgan: Generative adversarial networks for conditional waveform synthesis”, *arXiv preprint arXiv:1910.06711*, 2019. <https://doi.org/10.48550/arXiv.1910.06711>
- [11] C. Donahue, J. McAuley, i M. Puckette, “Adversarial audio synthesis”, *arXiv preprint arXiv:1802.04208*, 2018. <https://doi.org/10.48550/arXiv.1802.04208>
- [12] D. P. Kingma i M. Welling, “Auto-encoding variational bayes”, *arXiv preprint arXiv:1312.6114*, 2013. <https://doi.org/10.48550/arXiv.1312.6114>
- [13] J. Lucas, G. Tucker, R. B. Grosse, i M. Norouzi, “Don’t blame the ELBO! a linear VAE perspective on posterior collapse”, u *Advances in Neural Information Processing Systems*, sv. 32, 2019.
- [14] R. Prenger, R. Valle, i B. Catanzaro, “Waveglow: A flow-based generative network for speech synthesis”, *arXiv preprint arXiv:1811.00002*, 2018. <https://doi.org/10.48550/arXiv.1811.00002>
- [15] J. Ho, A. Jain, i P. Abbeel, “Denoising diffusion probabilistic models”, u *Advances in Neural Information Processing Systems*, sv. 33, 2020., str. 6840–6851. [Mrežno]. Adresa: <https://arxiv.org/abs/2006.11239>
- [16] A. Hyvärinen, “Estimation of non-normalized statistical models by score matching”, *Journal of Machine Learning Research*, sv. 6, str. 695–709, 2005.
- [17] N. Chen, Y. Zhang, H. Zen, R. J. Weiss, M. Norouzi, i W. Chan, “Wavegrad: Estimating gradients for waveform generation”, *arXiv preprint arXiv:2009.00713*,

2020. <https://doi.org/10.48550/arXiv.2009.00713>

- [18] J. Song, C. Meng, i S. Ermon, “Denoising diffusion implicit models”, u *International Conference on Learning Representations*, 2021. [Mrežno]. Adresa: <https://arxiv.org/abs/2010.02502>
- [19] M. Božić i M. Horvat, “A survey of deep learning audio generation methods”, *arXiv preprint arXiv:2406.00146*, 2024. [Mrežno]. Adresa: <https://arxiv.org/abs/2406.00146>
- [20] R. Rombach, A. Blattmann, D. Lorenz, P. Esser, i B. Ommer, “High-resolution image synthesis with latent diffusion models”, u *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2022., str. 10 674–10 685. [Mrežno]. Adresa: <https://arxiv.org/abs/2112.10752>
- [21] I. Higgins, L. Matthey, A. Pal, C. Burgess, X. Glorot, M. Botvinick, S. Mohamed, i A. Lerchner, “beta-vae: Learning basic visual concepts with a constrained variational framework”, u *International Conference on Learning Representations*, 2017. [Mrežno]. Adresa: <https://openreview.net/forum?id=Sy2fchgI>
- [22] H. Liu, Z. Chen, Y. Yuan, X. Mei, X. Liu, D. Mandic, W. Wang, i M. D. Plumbley, “Audioldm: Text-to-audio generation with latent diffusion models”, *arXiv preprint arXiv:2301.12503*, 2023. <https://doi.org/10.48550/arXiv.2301.12503>
- [23] B. Elizalde, S. Deshmukh, M. Al Ismail, i H. Wang, “Clap: Learning audio concepts from natural language supervision”, u *ICASSP 2023 – IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. IEEE, 2023., str. 1–5. [Mrežno]. Adresa: <https://arxiv.org/abs/2206.04769>
- [24] K. Chen, Y. Wu, H. Liu, M. Nezhurina, T. Berg-Kirkpatrick, i S. Dubnov, “Musicldm: Enhancing novelty in text-to-music generation using beat-synchronous mixup strategies”, *arXiv preprint arXiv:2308.01546*, 2023. <https://doi.org/10.48550/arXiv.2308.01546>
- [25] T. Karchkhadze, M. R. Izadi, K. Chen, G. Assayag, i S. Dubnov, “Multi-track musicldm: Towards versatile music generation with latent diffusion model”, *arXiv*

preprint arXiv:2409.02845, 2024. <https://doi.org/10.48550/arXiv.2409.02845>

- [26] Z. Evans, J. D. Parker, C. Carr, Z. Zukowski, J. Taylor, i J. Pons, “Stable audio open”, *arXiv preprint arXiv:2407.14358*, 2024. <https://doi.org/10.48550/arXiv.2407.14358>
- [27] F. Schneider, O. Kamal, Z. Jin, i B. Schölkopf, “Moûsai: Text-to-music generation with long-context latent diffusion”, *arXiv preprint arXiv:2301.11757*, 2023. <https://doi.org/10.48550/arXiv.2301.11757>
- [28] Z. Evans, J. D. Parker, C. Carr, Z. Zukowski, J. Taylor, i J. Pons, “Long-form music generation with latent diffusion”, *arXiv preprint arXiv:2404.10301*, 2024. <https://doi.org/10.48550/arXiv.2404.10301>
- [29] Z. Rafii, A. Liutkus, F.-R. Stöter, S. I. Mimilakis, i R. Bittner, “The MUSDB18 corpus for music separation”, *prosinac* 2017. <https://doi.org/10.5281/zenodo.1117372>
- [30] A. Agostinelli, T. I. Denk, Z. Borsos, J. Engel, M. Verzetti, A. Caillon, Q. Huang, A. Jansen, A. Roberts, M. Tagliasacchi, M. Sharifi, N. Zeghidour, i C. Frank, “Musiclm: Generating music from text”, *arXiv preprint arXiv:2301.11325*, 2023. <https://doi.org/10.48550/arXiv.2301.11325>
- [31] M. Defferrard, K. Benzi, P. Vandergheynst, i X. Bresson, “Fma: A dataset for music analysis”, u *Proceedings of the International Society for Music Information Retrieval Conference (ISMIR)*, 2017. [Mrežno]. Adresa: <https://arxiv.org/abs/1612.01840>
- [32] K. Kilgour, M. Zuluaga, D. Roblek, i M. Sharifi, “Fréchet audio distance: A metric for evaluating music enhancement algorithms”, *arXiv preprint arXiv:1812.08466*, 2019. <https://doi.org/10.48550/arXiv.1812.08466>
- [33] S. Hershey, S. Chaudhuri, D. P. W. Ellis, J. F. Gemmeke, A. Jansen, R. C. Moore, M. Plakal, D. Platt, R. A. Saurous, B. Seybold, M. Slaney, R. J. Weiss, i K. Wilson, “Cnn architectures for large-scale audio classification”, u *Proceedings of the IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, 2017., str. 131–135. <https://doi.org/10.1109/ICASSP.2017.7952132>
- [34] Y. Li, R. Yuan, G. Zhang, Y. Ma, X. Chen, H. Yin, C. Xiao, C. Lin, A. Ragni, E. Benetos, N. Gyenge, R. Dannenberg, R. Liu, W. Chen, G. Xia, Y. Shi,

- W. Huang, Z. Wang, Y. Guo, i J. Fu, “Mert: Acoustic music understanding model with large-scale self-supervised training”, *arXiv preprint arXiv:2306.00107*, 2023., accepted at ICLR 2024. <https://doi.org/10.48550/arXiv.2306.00107>
- [35] J. Yao, G. Ma, H. Xue, H. Chen, C. Hao, Y. Jiang, H. Liu, R. Yuan, J. Xu, W. Xue, H. Liu, i L. Xie, “Songeval: A benchmark dataset for song aesthetics evaluation”, *arXiv preprint arXiv:2505.10793*, 2025. <https://doi.org/10.48550/arXiv.2505.10793>
- [36] Y. Chung, P. Eu, J. Lee, K. Choi, J. Nam, i B. S. Chon, “Kad: No more fad! an effective and efficient evaluation metric for audio generation”, *arXiv preprint arXiv:2502.15602*, 2025. <https://doi.org/10.48550/arXiv.2502.15602>
- [37] ITU-T, “ITU-T Recommendation P.800: Methods for Subjective Determination of Transmission Quality”, <https://www.itu.int/rec/T-REC-P.800>, 1996., international Telecommunication Union.
- [38] ITU-R, “ITU-R BS.1534-3: Method for the subjective assessment of intermediate quality level of audio systems”, <https://www.itu.int/rec/R-REC-BS.1534>, 2015., mUSHRA listening test recommendation.
- [39] G. Peeters, “A large set of audio features for sound description (similarity and classification) in the CUIDADO project”, IRCAM, teh. izv., 2004. [Mrežno]. Adresa: http://recherche.ircam.fr/anasyn/peeters/ARTICLES/Peeters_2003_cuidadoaudiofeatures.pdf
- [40] A. Paszke, S. Gross, F. Massa, A. Lerer, J. Bradbury, G. Chanan, T. Killeen, Z. Lin, N. Gimelshein, L. Antiga, A. Desmaison, A. Kopf, E. Yang, Z. DeVito, M. Raison, A. Tejani, S. Chilamkurthy, B. Steiner, L. Fang, J. Bai, i S. Chintala, “Pytorch: An imperative style, high-performance deep learning library”, u *Advances in Neural Information Processing Systems*, sv. 32, 2019., str. 8024–8035.
- [41] S. Elfving, E. Uchibe, i K. Doya, “Sigmoid-weighted linear units for neural network function approximation in reinforcement learning”, *Neural Networks*, sv. 107, str. 3–11, 2018. <https://doi.org/10.1016/j.neunet.2017.12.012>
- [42] Y. Wu i K. He, “Group normalization”, u *Proceedings of the European*

Conference on Computer Vision (ECCV), 2018., str. 3–19. [Mrežno]. Adresa: <https://arxiv.org/abs/1803.08494>

- [43] O. Ronneberger, P. Fischer, i T. Brox, “U-net: Convolutional networks for biomedical image segmentation”, u *Medical Image Computing and Computer-Assisted Intervention (MICCAI)*, ser. Lecture Notes in Computer Science, sv. 9351. Springer, 2015., str. 234–241. [Mrežno]. Adresa: <https://arxiv.org/abs/1505.04597>
- [44] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, Ł. Kaiser, i I. Polosukhin, “Attention is all you need”, u *Advances in Neural Information Processing Systems*, sv. 30, 2017. [Mrežno]. Adresa: <https://arxiv.org/abs/1706.03762>

Izjava o korištenju umjetne inteligencije

Korišteni UI alati:

Perplexity AI Search (perplexity.ai, pristupljeno lipnja 2026.)

- pretraživanje i sažimanje relevantnih radova u istraživačkom području,
- provjera točnosti tvrdnji u napisanim odlomcima,
- ispravljanje grešaka u programskoj implementaciji,

Perplexity AI Deep Research (perplexity.ai, pristupljeno lipnja 2026.)

- razrada ideja i prijedlozi eksperimenata,
- dorada jezičnog izražaja (ispravljanje gramatičkih grešaka, preformulacija nespretnih rečenica),

Osvrt na korištenje umjetne inteligencije: Alati umjetne inteligencije korišteni su kao pomoćno sredstvo u pojedinim fazama izrade rada, pri čemu je sav generirani sadržaj podvrgnut kritičkoj procjeni i autorskoj doradi. Jezične prijedloge UI alata prihvaćane su selektivno, uz vlastitu prosudbu o stilu i točnosti. Pri pretraživanju literature, sve reference predložene ili pronađene uz pomoć UI-ja samostalno su verificirane. Prijedlozi eksperimenata i idejnih rješenja korišteni su isključivo kao polazišna točka za vlastito kritičko promišljanje, a konačne odluke o metodologiji i implementaciji su samostalno donešene. Ispravljanje grešaka u programskom kodu provedene su uz razumijevanje uzroka pogreške, a ne slijepim preuzimanjem predloženih ispravaka.

Izjava o korištenju umjetne inteligencije: Potvrđujem da sam tijekom izrade ovog diplomskog rada koristio umjetnu inteligenciju u skladu s Politikom primjerenog ko-

rištenja umjetne inteligencije na Fakultetu elektrotehnike i računarstva, te da umjetna inteligencija nije zamijenila moje kritičko razmišljanje niti moj doprinos.